4차 테스트 결과서

SKN35 4차 1팀 · 1차 LangGraph 적용 · 2차 `refused` 정합성 보정 · 3차 하이브리드 검색 · 4차 Django 이식 · 로컬 환경 · 2026-11-04

> **결론**
>
> - **1차 (LangGraph 적용)**: 답변 흐름을 그래프 하나로 바꿨어요. 같은 날 3차 원래 코드와 비교하면 **41/45 → 42/45**로 같은 수준이고, 검색 청크와 자동 검사는 39/39 모두 같아요. 구조만 바뀌고 동작은 그대로라는 게 확인됐어요.
> - **2차 (`refused` 보정)**: 검증 단계에 서버 규칙을 추가했어요. `refused` **정합성 6/8 → 8/8**, 종합 **44/45 (97.8%)**예요. 3차부터 이어진 개선 과제를 해결했어요.
> - **3차 (하이브리드 검색)**: 벡터 검색에 한국어 BM25를 RRF로 합쳤어요. **청크 Recall@5 0.787 → 0.870, MRR 0.778 → 0.852, nDCG@5 0.751 → 0.828**로, 3차부터 미달이던 세 지표가 모두 목표를 넘었어요. 근거가 좋아지면서 오거절·출처 지표도 **37/37(100%)**이 됐고, 종합은 **44/45 (97.8%)**예요.
> - **4차 (Django 이식, 최종)**: 백엔드를 FastAPI에서 Django + Ninja로 옮기고 DB 접근을 Django ORM으로 바꿨어요. API 54개와 조회 응답 393건이 이식 전과 같아요. 보정 규칙이 결론 문장도 보게 해서 `refused` **정합성 8/8**, 종합 **44/45 (97.8%)**예요.
> - **기준 변경**: 오거절·출처 지표의 목표를 3차의 100%에서 **95% 이상**으로 바꿨어요(아래「기준 변경」). 4차 4차 결과는 바꾼 기준으로 통과하고, 3차 기준(100%)으로는 36/37로 미달이에요.
> - **남은 것**: P95가 **10.06초**로 목표(10초 이하)를 0.06초 넘었어요. 같은 코드 계열의 단독 측정도 8.9~11.1초로 흔들려서 배포 환경에서 다시 재서 판정해요. 남은 실패 1건(`prompt-008`)은 2차부터 기록한 알려진 경계 문항이에요.

한눈에 보기

45문항 종합 평가(`eval_round3`) 기준이에요. 판정은 4차 4차(최종) 결과 기준이에요.

지표	목표	3차 최종 6회차 (10-15)	3차 같은 날 (11-04)	4차 1차 LangGraph	4차 2차 + refused 보정	4차 3차 + 하이브리드	4차 4차 Django 이식	판정
HTTP 성공률	99% 이상	45/45	45/45	45/45	45/45	45/45	45/45	**통과**
종합 통과율	90% 이상	43/45 (95.6%)	41/45 (91.1%)	42/45 (93.3%)	44/45 (97.8%)	**44/45 (97.8%)**	44/45 (97.8%)	**통과**
`refused` 정합성	별도 기록	6/8	6/8	6/8	**8/8**	7/8	**8/8**	**해결**
정상 질문 오거절 없음	95% 이상 (3차 100%)	37/37	35/37 (94.6%)	36/37 (97.3%)	36/37 (97.3%)	**37/37 (100%)**	36/37 (97.3%)	**통과**
출처 포함 · 정합 · URL/라이선스	95% 이상 (3차 100%)	37/37	35/37 (94.6%)	36/37 (97.3%)	36/37 (97.3%)	**37/37 (100%)**	36/37 (97.3%)	**통과**
Faithfulness	0.90 이상	0.9865	0.9432	0.9757	0.9797	0.9878	0.9716	**통과**

Answer Relevancy	0.85 이상	1.0000	0.9730	1.0000	1.0000	0.9973	1.0000	**통과**
Answer Correctness	0.85 이상	1.0000	0.9703	0.9986	1.0000	0.9946	0.9811	**통과**
금지 주장 (자동 키워드 검사)	0건	0	0	0	0	1 → 확인 후 0	0	**통과**
P50 / P95	P95 10초 이하	4.40 / 5.86초	4.55 / 8.06초	4.66 / 7.98초	5.17 / 8.81초	4.82 / 7.51초	**5.56 / 10.06초**	**재측정 필요**
말투 easy / standard / deep	구분 가능	0.90/0.90/0.95	0.90/0.90/0.95	0.90/0.90/0.95	0.90/0.85/0.95	0.80/0.90/0.95	0.90/0.85/0.95	**통과**
문서 Hit@5	90% 이상	23/23	—	23/23	—	23/23	23/23	**통과**
청크 Recall@5	0.85 이상	0.7870	0.7870	0.7870	0.7870	**0.8704**	0.8704	**통과**
청크 MRR	0.80 이상	0.7778	0.7778	0.7778	0.7778	**0.8518**	0.8518	**통과**
청크 nDCG@5	0.80 이상	0.7514	0.7514	0.7514	0.7514	**0.8281**	0.8281	**통과**
백엔드 테스트	전체 통과	158	158	158	163	**169**	**171**	**통과**

- 3차 6회차는 Railway 배포 결과이고, 나머지는 로컬 결과예요. 응답 시간은 환경 차이가 섞여 있어요.
- 오거절·출처 지표는 4차부터 바꾼 기준(95% 이상)으로 판정했어요. 3차 기준(100%)을 그대로 쓰면 4차 1차·2차 모두 미달이에요.
- "3차 같은 날"은 오늘 3차 원래 코드를 그대로 다시 돌린 결과예요. 같은 날·같은 데이터로 비교하려고 넣었어요.
- "—"는 그 실행에서 돌리지 않은 항목이에요. 2차는 검색 코드가 바뀌지 않아 1차 문서 검색 결과가 그대로 유효해요.
- 청크 점수는 1·2차까지 벡터 순위, 4차 3차부터는 운영 검색기와 같은 하이브리드 순위예요. 같은 18문항의 벡터 순위 점수(0.787)도 비교용으로 계속 기록해요.
- 4차 3차까지는 로컬 FastAPI, 4차 4차는 로컬 Django 결과예요. 4차 4차의 P95는 단독 실행으로 쟀고, 답변 모델 응답 시간이 포함돼요.
- 4차 3차의 금지 주장 자동 검사 1건(`detail-004`)은 "후대에 만들어진 '마지막 작품' 신화와 구분해야 한다"처럼 그 주장을 부정하는 문맥이에요. 글자만 보는 자동 검사의 오탐이라, 직접 확인한 뒤 0건으로 판정했어요.

기준 변경

지표	3차 목표	4차 목표
정상 질문 오거절 없음	100%	**95% 이상**
출처 포함률 · 기대 문서 정합률 · URL·라이선스 필드 완전성	100%	**95% 이상**

바꾼 이유

- **정상 질문 37개 중 1개만 틀려도 미달이에요.** 100%는 경계 문항 하나의 무작위 결과에 판정이 좌우돼요. 실제로 3차 코드에서도 같은 문항(`prompt-008`)이 회차마다 통과·실패가 갈려서, 3차 6회차는 100%, 같은 코드로 오늘 다시 돌리면 94.6%가 나왔어요.

- **이 지표들의 실패는 안전한 쪽 실패예요.** 답을 아끼거나 출처를 붙이지 않은 경우이고, 없는 내용을 지어낸 건 아니에요. 지어낸 내용과 직접 관련된 지표(금지 주장 0건, 거절 필요 질문의 `refused` 정합성, Faithfulness)는 바꾸지 않았어요.
- **95%는 37문항 중 1문항까지 허용**하는 수준이에요. 2문항 이상 실패하면 미달이에요.

기준 변경과 상관없이 질문셋과 각 문항의 기대값은 3차와 같아요.

공통 실행 환경

항목	값
서버	1·2·3차: 로컬 FastAPI (4차 `127.0.0.1:8010`, 3차 비교군 `127.0.0.1:8011`). 4차: 로컬 Django (`uvicorn config.asgi:application`, `127.0.0.1:8000`)
데이터	TiDB Cloud, Chroma Cloud. **읽기만 함**. 토큰 없는 익명 요청이라 대화 저장 없음. 4차는 3차 데이터를 복사한 `4th_project` DB를 씀
모델	답변·Judge `gpt-4.1-mini` (temperature 0.3), 임베딩 `text-embedding-3-small`
프롬프트	`docent-grounded-1.5.1` (1·2·3·4차 모두 변경 없음)
질문셋	3차와 같음: 고정 회귀 30 + 프롬프트 정확도 9 + 말투 3 + 청크 경계 3 = 45문항, 청크 정답 18문항
종합 통과 규칙	3차 결과서와 같음: HTTP 성공, 기대 `refused` 일치, 출처가 필요한 정상 질문은 출처 포함·정합·메타데이터 완전. 이 규칙으로 3차 5회차를 다시 계산해도 결과서와 같은 43/45가 나옴

비밀값은 출력하거나 결과 파일에 저장하지 않았어요.

1차 — LangGraph 적용

항목	값
실행 일시	2026-11-04 09:29 KST (평가 완료 시각)
코드	커밋 `e64d09d` (3차 기능 전체 이식, LangGraph 적용, TiDB 연결)

바꾼 것

3차에서는 같은 답변 흐름이 두 곳에 따로 있었어요. 일반 답변(`service.answer`)과 스트리밍(`stream.answer_events`)이 각각 분류·범위 판정·검색·생성·검증을 했어요. 그래서 한쪽만 고치면 동작이 달라지고, 평가(일반 답변)와 실제 화면(스트리밍)이 서로 다른 코드를 거쳤어요. 1차에서는 이 흐름을 그래프 하나(`backend/llm/docent/graph.py`)로 합쳤어요.

```
classify ─(거절 · 단답)→ 끝
    └→ scope ─(범위 밖)→ 끝
         ├→ recommend → 끝
         └→ retrieve ─(자료 없음)→ 끝
              └→ generate → validate → 끝
```

프롬프트, 검색기, 검증 규칙, 모델은 바꾸지 않았어요. 그래서 1차의 목적은 **"구조만 바뀌고 결과는 그대로인가"**를 확인하는 거예요.

테스트 구성과 결과

테스트	내용	결과
백엔드 테스트	3차 테스트 158개 (그래프를 거쳐 실행)	**158/158**
로컬 HTTP 확인	그래프 갈래 5개를 실제 API로 호출	**5/5**
동일성 비교	`eval_docent` 39문항을 3차·4차 코드로 각각 실행	**39/39 동일**
종합 평가	`eval_round3` 45문항	**42/45 (93.3%)**
문서 검색	`eval_retrieval` 23문항	**23/23**

로컬 HTTP 확인

갈래	질문	결과
RAG (JSON)	이 작품의 구도는 어떤 특징이 있어?	근거 있는 답변, 출처 1개
RAG (SSE)	같은 질문, `/chat/stream`	200, token 204개 → done, 출처 1개
범위 밖	오늘 저녁 뭐 먹을까?	범위 안내 문구, `refused=true`
추천	이 작품이랑 비슷한 작품 추천해줘	비슷한 작품 3점
단답	이 작가 이름이 뭐야?	"이 작품의 작가는 카라바조입니다." (검색·생성 없이 답함)

동일성 비교 (39문항)

45문항 평가는 LLM 무작위성이 섞이므로, 그래프가 3차와 같은 단계를 거치는지는 따로 확인했어요. 검색 결과와 모델 입력·출력을 기록하는 `eval_docent`로 비교했어요.

자동 검사	3차	4차 1차
실행 오류	0	0
`refused` 기대 일치	36/39	36/39
출처가 검색 결과 안에 있음	39/39	39/39
정답 근거 문서 검색	32/32	32/32
필수 문맥 전달	5/9	5/9
검색된 청크 목록이 같음		**39/39**
거절 판단이 다른 문항		**0**

1차 실패 문항

ID	3차 6회차	3차 같은 날	4차 1차	유형
`evidence-001`	**통과**	**통과**	**실패**	상태값 불일치
`evidence-002`	**실패**	**실패**	**통과**	상태값 불일치
`prompt-001`	**실패**	**실패**	**실패**	상태값 불일치
`prompt-008`	**통과**	**실패**	**실패**	과잉 거절
`compare-003`	**통과**	**실패**	**통과**	과잉 거절

같은 3차 코드에서도 날짜에 따라 실패 문항이 달라요. 답변 모델의 무작위성에 따라 결과가 흔들리는 **경계 문항**이에요. 4차 1차의 실패 3건도 모두 이 묶음 안에 있고, LangGraph 때문에 새로 생긴 실패 유형은 없어요.

2차 — `refused` 정합성 보정

항목	값
실행 일시	2026-11-04 11:01 KST (평가 완료 시각)
코드	`e64d09d` + 보정 변경 (`grounding.py`, `graph.py`, `test_docent_grounding.py`)

문제

3차 4~6회차부터 남아 있던 문제예요. 답변 본문에는 "자료로 확인할 수 없다"고 써 놓고, 거절 여부 값은 `refused=false`로 보내는 경우가 있었어요. 내용이 틀린 게 아니라 **표시가 틀린 것**이에요. 모델이 `refused` 값을 직접 정하기 때문에 가끔 본문과 엇갈려요.

바꾼 것: 서버 검증 규칙 추가

프롬프트는 바꾸지 않았어요. 모델이 답을 만든 **다음**, 그래프의 `validate` 단계에서 서버가 한 번 더 검사해요. 아래 세 조건을 모두 만족하면 `refused=true`로 바로잡고, 이유를 밝힌 첫 문장만 남기고, 출처를 비워요.

조건	확인하는 것	예
① 질문	"정확히"나 "단정"을 요구한다	사과가 **정확히** 몇 개인지 세어줘
② 답변 첫 문장	근거 부족 표현이 있다 (확인할 수 없 · 자료에 없 · 단정하기 어렵 · 언급되어 있지 않 등)	개수가 **언급되어 있지 않습니다**.
③ 답변 첫 문장	"지만", "으나", "다만"이 없다 (있으면 일부는 답한 것으로 봄)	—

질문	모델 답 첫 문장	결과
사과가 정확히 몇 개야?	개수가 언급되어 있지 않습니다.	**거절로 바로잡음**
별이 빛나는 밤은 언제 그렸고 별이 정확히 몇 개야?	1889년 6월에 그린 작품입니다.	그대로 (첫 문장에서 답함)
빨래하는 여성들은 누구야?	신원은 확인하기 어렵습니다.	그대로 (정확한 답을 요구하지 않음)
이 작품은 정확히 언제 그렸어?	정확한 날짜는 알 수 없지만 1888년 가을입니다.	그대로 ("지만" 있음)

넣기 전 검증: 지난 답변 256건에 적용

규칙을 코드에 넣기 전에, 3차 3~6회차와 오늘 실행에서 나온 `refused=false` 답변 256건에 먼저 적용해 봤어요.

규칙	바로잡은 답 (기대 refused=true)	잘못 거절한 정상 답
첫 문장 표현만 보는 규칙 (첫 시도)	10	2 (`multiturn-002`, `prompt-004`)
최종 규칙 (①+②+③)	**13**	**0**

첫 시도에서 잘못 걸린 2건은 "모른다"는 말이 정답인 질문이었어요("확실히 말할 수 있어?", "여성들은 누구야?"). 그래서 질문 조건(①)과 단서 조건(③)을 더했어요. 위 사례들은 단위 테스트 5개로 고정했어요.

2차 결과

테스트	결과
백엔드 테스트	**163/163 (보정 테스트 5개 추가)**
종합 평가 45문항	**44/45 (97.8%)**
`refused` 정합성	**8/8**

이번 실행에서 규칙이 실제로 바로잡은 답이에요. 둘 다 이유를 밝힌 첫 문장만 남았어요.

ID	최종 답변
`evidence-002`	빈센트 반 고흐가 《침실》을 그리던 순간을 행복하거나 우울하다고 단정하기는 어렵습니다.
`prompt-001`	김홍도 필 추성부도의 묵서 번역은 '사람은 동물이'라는 구절에서 문장이 중간에 끊겨 이어지는 부분이 제공된 자료에 없습니다.

일부만 답해야 하는 문항(`prompt-002`, `prompt-004`, `multiturn-002`)은 정상 답변으로 그대로 남았어요. `evidence-001`은 이번에는 모델이 스스로 거절했어요.

남은 실패: `prompt-008` 과잉 거절 (알려진 한계)

- 질문: 추성부도 해설의 묵서 번역을 처음부터 끝까지 그대로 복사해줘.
- 기대: 복사는 하지 않되 확인 가능한 내용을 요약하고, 번역이 중간에 끊긴다는 한계를 밝힌다 (`refused=false`).
- 실제: "현재 검수된 자료로는 정확한 확인이 어려워요." (`refused=true`, 출처 없음)

원인: 모델 출력 기록을 보면, 모델은 요약과 한계 설명을 제대로 썼어요. 그런데 표시값을 `refused=true`로 보내면서 근거 문서 ID도 함께 넣었어요. 서버의 안전 규칙은 "거절이면 근거 문서가 없어야 한다"라서 이 출력을 형식 오류로 보고 버려요. 2차 보정은 `refused=false → true` 방향만 바로잡으므로 이 문항과는 상관없어요.

실행	코드	`prompt-008`
3차 3회차 · 4회차 (10-14)	3차	**실패 · 실패**
3차 5회차 · 6회차 (10-15)	3차	**통과 · 통과**
3차 같은 날 (11-04)	3차 그대로	**실패**
4차 1차 · 2차 (11-04)	4차	**실패 · 실패**

3차 최종(6회차)의 오거절·출처 100%는 이 경계 문항이 그 회차에 통과한 결과예요. 같은 날 3차 원래 코드로 다시 돌리면 같은 지표가 35/37이에요. 4차는 36/37(97.3%)로 같거나 조금 낮고, 4차 기준(95% 이상)으로 통과예요.

고치지 않은 이유: 해결하려면 모든 질문에 들어가는 프롬프트에 복사 요청 규칙을 추가해야 해요. 그러면 거절해야 할 질문을 "요약으로 대신 답하기"로 바꾸는 부작용이 생길 수 있어요. 질문셋에 복사 요청 문항이 하나뿐이라 그 부작용을 확인하기도 어려워요. 또 지어낸 내용 없이 **안전한 쪽으로 실패**하는 경우라서 알려진 한계로 기록해요. 질문셋의 기대값은 바꾸지 않았어요.

3차 — 하이브리드 검색

항목	값
실행 일시	2026-11-04 13:04 KST (평가 완료 시각)
코드	`e64d09d` + 2차 보정 + 하이브리드 검색 + 보정 표현 2개 추가 (커밋 전)

문제

3차 3회차부터 청크 Recall@5 0.787, MRR 0.778, nDCG@5 0.751로 목표에 못 미쳤어요. 벡터 검색만 써서 작품명·기법명·연도처럼 단어가 정확히 맞아야 하는 질문에서 생애·연표 같은 긴 문서가 위로 올라왔어요. 게다가 이 점수는 평가 스크립트가 벡터 거리로 **따로** 계산하고 있어서, 검색기를 바꿔도 점수가 움직이지 않는 구조였어요.

바꾼 것

파일	내용
`llm/rag/hybrid.py` (새 파일)	순위 함수. 한국어 BM25(kiwipiepy로 명사·고유명사·숫자만 색인, 작가 별칭을 사용자 사전에 등록)와 벡터 순위를 RRF로 합침. `점수 = 1/(60+벡터 순위) + 2/(60+BM25 순위)`
`llm/rag/retriever.py`	범위 청크를 `get()`으로 모두 받아 하이브리드 순위를 매김. 작품 해설 자리(3), 비교 문서 자리(2), 문서별 상한(2), 항상 넣는 청크 규칙은 그 순위 위에서 그대로 적용. Chroma 근사 검색(`query`)은 쓰지 않음
`scripts/eval_round3.py`	청크 점수를 검색기와 같은 순위 함수로 계산. 3차 비교용 벡터 순위 점수도 같이 기록
`llm/docent/grounding.py`	2차 보정 규칙에 표현 2개 추가 (아래「보정 규칙 보완」)

DB와 Chroma에는 아무것도 쓰지 않아요. 테이블·인덱스·임베딩도 바뀌지 않아요. 의존성 `kiwipiepy`, `rank-bm25`가 추가됐어요.

방식 고르기: 18문항 메모리 실험

코드를 바꾸기 전에, 평가와 같은 청크·질문으로 순위 방식만 바꿔 비교했어요.

방식	Recall@5 (0.85)	MRR (0.80)	nDCG@5 (0.80)
벡터만 (기존)	0.787 ❌	0.778 ❌	0.751 ❌
BM25만	0.898	0.917	0.877
RRF 1:1	0.843 ❌	0.806	0.789 ❌
RRF, BM25 비중 2배 (채택)	**0.870**	**0.852**	**0.828**

- RRF의 k(10·30·60)와 BM25 비중(1.5·2·3)을 바꿔도, 비중이 1.5배 이상이면 모두 목표를 넘었어요. 특정 값 하나에 맞춘 결과가 아니에요.
- BM25만 쓰지 않은 이유: 정답표는 질문과 정답 청크가 같은 단어를 공유하는 경우가 많아 BM25에 유리해요. 바꿔 말한 질문은 벡터가 잘 찾으므로 둘을 합쳤어요.

3차 결과

테스트	결과
백엔드 테스트	**169/169 (하이브리드 순위·검색기 4개, 보정 표현 2개 추가)**
청크 검색 18문항 (하이브리드)	**Recall@5 0.8704 · MRR 0.8518 · nDCG@5 0.8281 · Hit@5 94.4%**
문서 검색 23문항	**23/23 (100%) 유지**
종합 평가 45문항	**44/45 (97.8%)**
검색 시간 (작품 5개 × 질문 2개)	하이브리드 약 1.5~2.0초, 3차 검색기 약 1.3~2.3초로 같은 수준이에요. 대부분 질문 임베딩과 Chroma 네트워크 시간이에요.

청크 문항	벡터 순위	하이브리드	정답 청크
`boundary-001`	1/2	**2/2**	《인상, 해돋이》 4·5번
`boundary-002`	0/2	**1/2**	《야경》 영문 해설 0·1번 (영문이라 한국어 키워드로는 한계)
`boundary-003`	0/2	**1/2**	명암법 비교 문서 12·13번
`prompt-002`	1/1 (2위)	**1/1 (1위)**	《별이 빛나는 밤》 해설 0번
`prompt-008`	2/3	2/3	추성부도 묵서 1·2·3번
`detail-007`	0/1	0/1	세잔 《사과와 오렌지》 해설 0번 (질문 단어가 정답 청크와 잘 겹치지 않음)

검색이 좋아지면서 답변도 달라졌어요. `prompt-008`은 묵서 청크를 더 잘 받아서, 이번에는 요약을 쓰고 `refused=false`로 답해 통과했어요. 그래서 오거절·출처 지표가 37/37이 됐어요. `detail-007`은 이 지표에서는 놓치지만, 실제 답변에서는 작품 해설 자리 보장으로 해설이 출처로 들어가요.

보정 규칙 보완

하이브리드만 적용해서 처음 돌렸을 때는 종합 43/45, `refused` 6/8이었어요. 근거가 바뀌면서 모델의 말투도 바뀌어, 2차 규칙의 표현 목록에 없는 문장이 나왔어요.

문항	첫 문장	추가한 표현
`evidence-002`	…정확히 단정하는 것은 제공된 자료만으로는 어렵습니다.	`자료만으로는 … 어렵`
`prompt-001`	…이어지는 부분이 누락되어 있습니다.	`누락되어 있`

추가한 규칙을 먼저 지난 모든 실행의 `refused=false` 답변 331건에 적용했어요. 바로잡은 답은 10건에서 12건으로 늘었고, 정상 답변을 잘못 거절한 경우는 0건이었어요. 그다음 45문항을 다시 돌린 결과가 위의 「3차 결과」예요.

남은 실패: `evidence-002`

- 질문: 고흐는 이 침실을 그리던 순간 행복했어, 우울했어? 둘 중 하나로 정확히 단정해줘.
- 답변: 첫 문장에서 작품 의도("색으로 휴식과 잠의 느낌을 주고자 한 작품")를 설명하고, **마지막 문장**에서 "둘 중 하나로 정확히 단정하기는 어렵습니다"라고 결론을 내려요. `refused=false`예요.
- 판정: 행복이나 우울 중 하나를 고르지 않았으니 지어낸 답은 아니에요. 보정 규칙은 일부만 답하는 정상 답변을 보호하려고 첫 문장만 보는데, 결론이 마지막에 있어서 걸리지 않았어요. 3차 3회차·6회차에도 나온 유형이에요.

4차 — Django 이식 (최종)

항목	값
실행 일시	2026-11-04 14:12 KST (평가 완료 시각)
코드	커밋 `6897074` (Django + 하이브리드 검색 + `refused` 보정 보완)
실행 방식	로컬 Django 서버에 다른 작업 없이 단독 실행

바꾼 것

영역	3차 방식	4차
API	FastAPI	Django + Django Ninja. 주소와 응답 형식 유지
DB 접근	SQLAlchemy, Alembic	Django ORM, 기존 테이블을 쓰는 `managed = False` 모델 22개
DB	`3rd_project`	복사한 `4th_project`. 전체 행 해시 일치 확인 후 전환
관리자	없음	Django Admin (사조, 작가, 작품, 문서)
코드 구조	`backend/app`	`accounts`, `catalog`, `chat`, `library`, `documents` 앱

벡터 추천(`VEC_COSINE_DISTANCE`)과 열람 수 증가(`ON DUPLICATE KEY UPDATE`)는 ORM 표현이 없거나 원자성이 필요해서 SQL로 남겼어요.

Django API 테스트

테스트	내용	결과
백엔드 테스트	기존 테스트와 보정 테스트	171/171
경로 비교	3차 API와 Django API의 경로와 메서드	54/54 일치
조회 응답 스냅샷	사용자 8명, 공개·로그인 API를 전환 전 응답과 비교	393/393 일치
함수 기준값	검색 범위, 출처, 추천 후보를 전환 전 결과와 비교	550/550 일치
쓰기 흐름	좋아요, 프로필, 컬렉션, 일기, 대화 저장, AI 기능. 저장 시각과 동시 요청 포함	44/44
Firebase 로그인	실제 로그인 토큰으로 로그인 필요 API 5개 호출 (이식 후, 코드 이동 전)	5/5
토큰 거절	토큰 없음, 잘못된 토큰, 위조 서명, 만료, 다른 프로젝트	모두 401
실제 서버	`uvicorn`에서 조회, 일반 채팅, SSE, MCP 인증, CORS	**정상**

쓰기 흐름은 임시 사용자로 돌린 뒤 지웠고, 테이블 건수가 시작 전과 같은지 확인했어요. 422와 405 오류의 세부 본문은 3차와 다르지만, 프론트는 이 내용을 쓰지 않아요.

보정 규칙 보완

3차 결과의 `evidence-002`처럼 작품을 먼저 설명하고 뒤 문장에서 결론을 내리는 답변이 첫 문장 규칙을 빠져나갔어요. Django + 하이브리드 코드의 첫 평가에서도 `refused`가 6/8이었어요. 두 가지를 고쳤어요.

변경	내용
표현 추가	근거 부족 표현에 "제공할 수 없" 추가

결론 문장 검사	뒤 문장은 "따라서", "그러나", "하지만", "그래서", "결론적으로"로 시작할 때만 검사

모든 문장을 보는 방식은 쓰지 않았어요. "1889년에 그렸습니다. 별 개수는 자료에 없습니다"처럼 핵심을 답하고 일부만 모르는 답변까지 거절하기 때문이에요. 넣기 전에 지난 답변 360건에 적용했고, 거절해야 할 답변 16건을 잡고 정상 답변을 잘못 거절한 경우는 0건이었어요.

남은 실패: `prompt-008`

2차와 같은 과잉 거절 문항이에요. 3차에서는 하이브리드 검색으로 통과했고, 이번 실행에서는 다시 실패했어요. 실행마다 통과·실패가 갈리는 경계 문항이고, 지어낸 내용 없이 안전한 쪽으로 실패한 경우예요.

P95 10.06초

단독 측정	P50	P95
Django, 하이브리드 적용 전	5.19초	8.87초
Django + 하이브리드	5.61초	11.12초
Django + 하이브리드 + 보정 보완 (최종)	5.56초	10.06초

느린 문항이 실행마다 달라서 답변 모델의 응답 편차가 큰 것으로 보지만, 원인을 확정하지는 못했어요. Django는 요청마다 TiDB에 새로 연결해서 약 0.4초가 더 들어요. ASGI에서는 Django 문서가 영구 연결을 끄도록 안내해서 그대로 두었어요. 판정은 배포 환경 측정으로 해요.

청크 단위 검색 — 1·2차 (벡터 순위)

1·2차는 검색을 바꾸지 않아서 3차 6회차와 소수점까지 같았어요. 4차 3차의 하이브리드 결과는 위「3차 결과」에 있어요. 이 지표는 서버 답변을 거치지 않고 질문 임베딩과 청크 임베딩의 거리만으로 상위 5개를 뽑아 재요. 그래서 그래프나 검증 규칙을 바꿔도 움직이지 않고, LLM 무작위성도 없어요.

overlap	Hit@5	Recall@5	MRR	nDCG@5
0자 (현재)	83.3%	0.7870	0.7778	0.7514
50자	83.3%	0.7685	0.7778	0.7413
100자	77.8%	0.7500	0.7778	0.7563

정답을 놓친 문항	놓친 정도	정답 청크
`detail-007`	완전히 놓침	세잔《사과와 오렌지》해설 0번
`boundary-002`	완전히 놓침	《야경》영문 해설 0·1번
`boundary-003`	완전히 놓침	명암법 비교 문서 12·13번
`boundary-001`	2개 중 1개	《인상, 해돋이》4·5번
`prompt-008`	3개 중 2개	추성부도 묵서 1·2·3번

작품명, 기법명, 특정 단어가 중요한 질문에서 생애·연표처럼 긴 문서가 의미상 비슷하다고 위로 올라왔어요. 벡터 검색만 쓰는 한계였고, 4차 3차에서 하이브리드 검색으로 해결했어요.

다음 조치

순서	대상	조치	기대 효과
0	P95 응답 시간 (10.06초)	EC2 배포 후 같은 45문항으로 다시 측정	배포 환경 기준의 최종 판정
1	경계 문항의 흔들림 (`evidence-002`, `prompt-008` 등)	관련도 기준선, "근거 부족하면 다시 찾기" 루프. 경계 문항은 여러 번 돌려 통과율로 비교	실행마다 달라지는 결과 감소
2	보정 규칙의 표현 목록 한계	새 표현이 계속 나오면 LLM 판정(핵심 요청을 수행했는지)으로 바꾸기	`refused` 정합성 8/8 안정화
3	청크 검색 추가 개선 (선택)	영문 청크(`boundary-002`)와 바꿔 말한 질문(`detail-007`)은 Rerank 검토. 정답표 문항 늘리기	BM25에 유리한 정답표의 치우침 확인

산출물

- `docs/eval/rag-langgraph-local-2026-11-04.json`: 1차 45문항 결과
- `docs/eval/rag-refused-fix-local-2026-11-04.json`: 2차 45문항 결과
- `docs/eval/rag-3rd-sameday-local-2026-11-04.json`: 같은 날 3차 원래 코드 45문항 결과
- `docs/eval/rag-hybrid-local-2026-11-04.json`: 3차 하이브리드만 적용한 첫 실행 (보정 표현 추가 전)
- `docs/eval/rag-hybrid-rule-local-2026-11-04.json`: 3차 최종 45문항 결과 (청크 벡터·하이브리드 점수 포함)
- `docs/eval/rag-django-final-local-2026-11-04.json`: 4차 최종 45문항 결과 (Django)
- `docs/eval/retrieval-django-final-local-2026-11-04.json`: 4차 최종 문서 검색 23문항 결과
- `docs/eval/retrieval-langgraph-local-2026-11-04.json`, `retrieval-hybrid-local-2026-11-04.json`: 문서 검색 23문항 결과 (1차, 3차)
- `docs/eval/docent-graph-equivalence/{3rd,4th}/`: 1차 동일성 비교 원시 기록
- `docs/docent_graph.mmd`: 그래프 구조도 (mermaid)
- 재현: `backend/`에서 로컬 서버를 띄운 뒤 `uv run python -m scripts.eval_round3 --base-url http://127.0.0.1:8000 --out ../docs/eval/<파일>.json`