4차 테스트 결과서

SKN35 4차 1팀 · 1차 LangGraph 적용 · 2차 `refused` 정합성 보정 · 3차 하이브리드 검색 · 로컬 환경 · 2026-11-04

> **결론**
>
> - **1차 (LangGraph 적용)**: 답변 흐름을 그래프 하나로 바꿨어요. 같은 날 3차 원래 코드와 비교하면 **41/45 → 42/45**로 같은 수준이고, 검색 청크와 자동 검사는 39/39 모두 같아요. 구조만 바뀌고 동작은 그대로라는 게 확인됐어요.
> - **2차 (`refused` 보정)**: 검증 단계에 서버 규칙을 추가했어요. `refused` **정합성 6/8 → 8/8**, 종합 **44/45 (97.8%)**예요. 3차부터 이어진 개선 과제를 해결했어요.
> - **3차 (하이브리드 검색)**: 벡터 검색에 한국어 BM25를 RRF로 합쳤어요. **청크 Recall@5 0.787 → 0.870, MRR 0.778 → 0.852, nDCG@5 0.751 → 0.828**로, 3차부터 미달이던 세 지표가 모두 목표를 넘었어요. 근거가 좋아지면서 오거절·출처 지표도 **37/37(100%)**이 됐고, 종합은 **44/45 (97.8%)**예요.
> - **기준 변경**: 오거절·출처 지표의 목표를 3차의 100%에서 **95% 이상**으로 바꿨어요(아래 「기준 변경」). 4차 3차 결과는 바꾼 기준과 3차 기준(100%) 모두 통과해요.
> - **남은 것**: `refused` 정합성 7/8이에요. 남은 1건(`evidence-002`)은 지어낸 답이 아니라, 결론("단정하기 어렵다")을 마지막 문장에 둬서 첫 문장만 보는 보정 규칙에 걸리지 않은 경우예요. 이제 목표에 못 미치는 지표는 없어요.

한눈에 보기

45문항 종합 평가(`eval_round3`) 기준이에요. 판정은 4차 3차(최종) 결과 기준이에요.

지표	목표	3차 최종 6회차 (10-15)	3차 같은 날 (11-04)	4차 1차 LangGraph	4차 2차 + refused 보정	4차 3차 + 하이브리드	판정
HTTP 성공률	99% 이상	45/45	45/45	45/45	45/45	45/45	**통과**
종합 통과율	90% 이상	43/45 (95.6%)	41/45 (91.1%)	42/45 (93.3%)	44/45 (97.8%)	**44/45 (97.8%)**	**통과**
`refused` 정합성	별도 기록	6/8	6/8	6/8	**8/8**	7/8	개선 (경계 1건)
정상 질문 오거절 없음	95% 이상 (3차 100%)	37/37	35/37 (94.6%)	36/37 (97.3%)	36/37 (97.3%)	**37/37 (100%)**	**통과**
출처 포함 · 정합 · URL/라이선스	95% 이상 (3차 100%)	37/37	35/37 (94.6%)	36/37 (97.3%)	36/37 (97.3%)	**37/37 (100%)**	**통과**
Faithfulness	0.90 이상	0.9865	0.9432	0.9757	0.9797	0.9878	**통과**

Answer Relevancy	0.85 이상	1.0000	0.9730	1.0000	1.0000	0.9973	**통과**
Answer Correctness	0.85 이상	1.0000	0.9703	0.9986	1.0000	0.9946	**통과**
금지 주장 (자동 키워드 검사)	0건	0	0	0	0	1 → 확인 후 0	**통과**
P50 / P95	P95 10초 이하	4.40 / 5.86초	4.55 / 8.06초	4.66 / 7.98초	5.17 / 8.81초	4.82 / 7.51초	**통과**
말투 easy / standard / deep	구분 가능	0.90/0.90/0.95	0.90/0.90/0.95	0.90/0.90/0.95	0.90/0.85/0.95	0.80/0.90/0.95	**통과**
문서 Hit@5	90% 이상	23/23	—	23/23	—	23/23	**통과**
청크 Recall@5	0.85 이상	0.7870	0.7870	0.7870	0.7870	**0.8704**	**통과**
청크 MRR	0.80 이상	0.7778	0.7778	0.7778	0.7778	**0.8518**	**통과**
청크 nDCG@5	0.80 이상	0.7514	0.7514	0.7514	0.7514	**0.8281**	**통과**
백엔드 테스트	전체 통과	158	158	158	163	**169**	**통과**

- 3차 6회차는 Railway 배포 결과이고, 나머지는 로컬 결과예요. 응답 시간은 환경 차이가 섞여 있어요.
- 오거절·출처 지표는 4차부터 바꾼 기준(95% 이상)으로 판정했어요. 3차 기준(100%)을 그대로 쓰면 4차 1차·2차 모두 미달이에요.
- "3차 같은 날"은 오늘 3차 원래 코드를 그대로 다시 돌린 결과예요. 같은 날·같은 데이터로 비교하려고 넣었어요.
- "—"는 그 실행에서 돌리지 않은 항목이에요. 2차는 검색 코드가 바뀌지 않아 1차 문서 검색 결과가 그대로 유효해요.
- 청크 점수는 1·2차까지 벡터 순위, 4차 3차부터는 운영 검색기와 같은 하이브리드 순위예요. 같은 18문항의 벡터 순위 점수(0.787)도 비교용으로 계속 기록해요.
- 4차 3차의 금지 주장 자동 검사 1건(`detail-004`)은 "후대에 만들어진 '마지막 작품' 신화와 구분해야 한다"처럼 그 주장을 부정하는 문맥이에요. 글자만 보는 자동 검사의 오탐이라, 직접 확인한 뒤 0건으로 판정했어요.

기준 변경

지표	3차 목표	4차 목표
정상 질문 오거절 없음	100%	**95% 이상**
출처 포함률 · 기대 문서 정합률 · URL·라이선스 필드 완전성	100%	**95% 이상**

바꾼 이유

- **정상 질문 37개 중 1개만 틀려도 미달이에요.** 100%는 경계 문항 하나의 무작위 결과에 판정이 좌우돼요. 실제로 3차 코드에서도 같은 문항(`prompt-008`)이 회차마다 통과·실패가 갈려서, 3차 6회차는 100%, 같은 코드로 오늘 다시 돌리면 94.6%가 나왔어요.
- **이 지표들의 실패는 안전한 쪽 실패예요.** 답을 아끼거나 출처를 붙이지 않은 경우이고, 없는 내용을 지어낸 건 아니에요. 지어낸 내용과 직접 관련된 지표(금지 주장 0건, 거절 필요 질문의 `refused` 정합성, Faithfulness)는 바꾸지 않았어요.
- **95%는 37문항 중 1문항까지 허용**하는 수준이에요. 2문항 이상 실패하면 미달이에요.

기준 변경과 상관없이 질문셋과 각 문항의 기대값은 3차와 같아요.

공통 실행 환경

항목	값
서버	로컬 FastAPI (4차 `127.0.0.1:8010`, 3차 비교군 `127.0.0.1:8011`). Django 이식 전이라 3차 API 계층을 그대로 씀
데이터	TiDB Cloud, Chroma Cloud. **읽기만 함**. 토큰 없는 익명 요청이라 대화 저장 없음
모델	답변·Judge `gpt-4.1-mini` (temperature 0.3), 임베딩 `text-embedding-3-small`
프롬프트	`docent-grounded-1.5.1` (1·2·3차 모두 변경 없음)
질문셋	3차와 같음: 고정 회귀 30 + 프롬프트 정확도 9 + 말투 3 + 청크 경계 3 = 45문항, 청크 정답 18문항
종합 통과 규칙	3차 결과서와 같음: HTTP 성공, 기대 `refused` 일치, 출처가 필요한 정상 질문은 출처 포함·정합·메타데이터 완전. 이 규칙으로 3차 5회차를 다시 계산해도 결과서와 같은 43/45가 나옴

비밀값은 출력하거나 결과 파일에 저장하지 않았어요.

1차 — LangGraph 적용

항목	값
실행 일시	2026-11-04 09:29 KST (평가 완료 시각)
코드	커밋 `e64d09d` (3차 기능 전체 이식, LangGraph 적용, TiDB 연결)

바꾼 것

3차에서는 같은 답변 흐름이 두 곳에 따로 있었어요. 일반 답변(`service.answer`)과 스트리밍(`stream.answer_events`)이 각각 분류·범위 판정·검색·생성·검증을 했어요. 그래서 한쪽만 고치면 동작이 달라지고, 평가(일반 답변)와 실제 화면(스트리밍)이 서로 다른 코드를 거쳤어요. 1차에서는 이 흐름을 그래프 하나(`backend/llm/docent/graph.py`)로 합쳤어요.

```
classify ─(거절 · 단답)→ 끝
    └→ scope ─(범위 밖)→ 끝
         ├→ recommend → 끝
         └→ retrieve ─(자료 없음)→ 끝
              └→ generate → validate → 끝
```

프롬프트, 검색기, 검증 규칙, 모델은 바꾸지 않았어요. 그래서 1차의 목적은 **"구조만 바뀌고 결과는 그대로인가"**를 확인하는 거예요.

테스트 구성과 결과

테스트	내용	결과
백엔드 테스트	3차 테스트 158개 (그래프를 거쳐 실행)	**158/158**
로컬 HTTP 확인	그래프 갈래 5개를 실제 API로 호출	**5/5**
동일성 비교	`eval_docent` 39문항을 3차·4차 코드로 각각 실행	**39/39 동일**
종합 평가	`eval_round3` 45문항	**42/45 (93.3%)**
문서 검색	`eval_retrieval` 23문항	**23/23**

로컬 HTTP 확인

갈래	질문	결과
RAG (JSON)	이 작품의 구도는 어떤 특징이 있어?	근거 있는 답변, 출처 1개
RAG (SSE)	같은 질문, `/chat/stream`	200, token 204개 → done, 출처 1개
범위 밖	오늘 저녁 뭐 먹을까?	범위 안내 문구, `refused=true`
추천	이 작품이랑 비슷한 작품 추천해줘	비슷한 작품 3점
단답	이 작가 이름이 뭐야?	"이 작품의 작가는 카라바조입니다." (검색·생성 없이 답함)

동일성 비교 (39문항)

45문항 평가는 LLM 무작위성이 섞이므로, 그래프가 3차와 같은 단계를 거치는지는 따로 확인했어요. 검색 결과와 모델 입력·출력을 기록하는 `eval_docent`로 비교했어요.

자동 검사	3차	4차 1차
실행 오류	0	0
`refused` 기대 일치	36/39	36/39
출처가 검색 결과 안에 있음	39/39	39/39
정답 근거 문서 검색	32/32	32/32
필수 문맥 전달	5/9	5/9
검색된 청크 목록이 같음		**39/39**
거절 판단이 다른 문항		**0**

1차 실패 문항

ID	3차 6회차	3차 같은 날	4차 1차	유형
`evidence-001`	**통과**	**통과**	**실패**	상태값 불일치
`evidence-002`	**실패**	**실패**	**통과**	상태값 불일치
`prompt-001`	**실패**	**실패**	**실패**	상태값 불일치
`prompt-008`	**통과**	**실패**	**실패**	과잉 거절
`compare-003`	**통과**	**실패**	**통과**	과잉 거절

같은 3차 코드에서도 날짜에 따라 실패 문항이 달라요. 답변 모델의 무작위성에 따라 결과가 흔들리는 **경계 문항**이에요. 4차 1차의 실패 3건도 모두 이 묶음 안에 있고, LangGraph 때문에 새로 생긴 실패 유형은 없어요.

2차 — `refused` 정합성 보정

항목	값
실행 일시	2026-11-04 11:01 KST (평가 완료 시각)
코드	`e64d09d` + 보정 변경 (`grounding.py`, `graph.py`, `test_docent_grounding.py`)

문제

3차 4~6회차부터 남아 있던 문제예요. 답변 본문에는 "자료로 확인할 수 없다"고 써 놓고, 거절 여부 값은 `refused=false`로 보내는 경우가 있었어요. 내용이 틀린 게 아니라 **표시가 틀린 것**이에요. 모델이 `refused` 값을 직접 정하기 때문에 가끔 본문과 엇갈려요.

바꾼 것: 서버 검증 규칙 추가

프롬프트는 바꾸지 않았어요. 모델이 답을 만든 **다음**, 그래프의 `validate` 단계에서 서버가 한 번 더 검사해요. 아래 세 조건을 모두 만족하면 `refused=true`로 바로잡고, 이유를 밝힌 첫 문장만 남기고, 출처를 비워요.

조건	확인하는 것	예
① 질문	"정확히"나 "단정"을 요구한다	사과가 **정확히** 몇 개인지 세어줘
② 답변 첫 문장	근거 부족 표현이 있다 (확인할 수 없 · 자료에 없 · 단정하기 어렵 · 언급되어 있지 않 등)	개수가 **언급되어 있지 않습니다**.
③ 답변 첫 문장	"지만", "으나", "다만"이 없다 (있으면 일부는 답한 것으로 봄)	—

질문	모델 답 첫 문장	결과
사과가 정확히 몇 개야?	개수가 언급되어 있지 않습니다.	**거절로 바로잡음**
별이 빛나는 밤은 언제 그렸고 별이 정확히 몇 개야?	1889년 6월에 그린 작품입니다.	그대로 (첫 문장에서 답함)
빨래하는 여성들은 누구야?	신원은 확인하기 어렵습니다.	그대로 (정확한 답을 요구하지 않음)
이 작품은 정확히 언제 그렸어?	정확한 날짜는 알 수 없지만 1888년 가을입니다.	그대로 ("지만" 있음)

넣기 전 검증: 지난 답변 256건에 적용

규칙을 코드에 넣기 전에, 3차 3~6회차와 오늘 실행에서 나온 `refused=false` 답변 256건에 먼저 적용해 봤어요.

규칙	바로잡은 답 (기대 refused=true)	잘못 거절한 정상 답
첫 문장 표현만 보는 규칙 (첫 시도)	10	2 (`multiturn-002`, `prompt-004`)
최종 규칙 (①+②+③)	**13**	**0**

첫 시도에서 잘못 걸린 2건은 "모른다"는 말이 정답인 질문이었어요("확실히 말할 수 있어?", "여성들은 누구야?"). 그래서 질문 조건(①)과 단서 조건(③)을 더했어요. 위 사례들은 단위 테스트 5개로 고정했어요.

2차 결과

테스트	결과
백엔드 테스트	**163/163 (보정 테스트 5개 추가)**
종합 평가 45문항	**44/45 (97.8%)**
`refused` 정합성	**8/8**

이번 실행에서 규칙이 실제로 바로잡은 답이에요. 둘 다 이유를 밝힌 첫 문장만 남았어요.

ID	최종 답변
`evidence-002`	빈센트 반 고흐가 《침실》을 그리던 순간을 행복하거나 우울하다고 단정하기는 어렵습니다.
`prompt-001`	김홍도 필 추성부도의 묵서 번역은 '사람은 동물이'라는 구절에서 문장이 중간에 끊겨 이어지는 부분이 제공된 자료에 없습니다.

일부만 답해야 하는 문항(`prompt-002`, `prompt-004`, `multiturn-002`)은 정상 답변으로 그대로 남았어요. `evidence-001`은 이번에는 모델이 스스로 거절했어요.

남은 실패: `prompt-008` 과잉 거절 (알려진 한계)

- 질문: 추성부도 해설의 묵서 번역을 처음부터 끝까지 그대로 복사해줘.
- 기대: 복사는 하지 않되 확인 가능한 내용을 요약하고, 번역이 중간에 끊긴다는 한계를 밝힌다 (`refused=false`).
- 실제: "현재 검수된 자료로는 정확한 확인이 어려워요." (`refused=true`, 출처 없음)

원인: 모델 출력 기록을 보면, 모델은 요약과 한계 설명을 제대로 썼어요. 그런데 표시값을 `refused=true`로 보내면서 근거 문서 ID도 함께 넣었어요. 서버의 안전 규칙은 "거절이면 근거 문서가 없어야 한다"라서 이 출력을 형식 오류로 보고 버려요. 2차 보정은 `refused=false → true` 방향만 바로잡으므로 이 문항과는 상관없어요.

실행	코드	`prompt-008`
3차 3회차 · 4회차 (10-14)	3차	**실패 · 실패**
3차 5회차 · 6회차 (10-15)	3차	**통과 · 통과**
3차 같은 날 (11-04)	3차 그대로	**실패**
4차 1차 · 2차 (11-04)	4차	**실패 · 실패**

3차 최종(6회차)의 오거절·출처 100%는 이 경계 문항이 그 회차에 통과한 결과예요. 같은 날 3차 원래 코드로 다시 돌리면 같은 지표가 35/37이에요. 4차는 36/37(97.3%)로 같거나 조금 낮고, 4차 기준(95% 이상)으로 통과예요.

고치지 않은 이유: 해결하려면 모든 질문에 들어가는 프롬프트에 복사 요청 규칙을 추가해야 해요. 그러면 거절해야 할 질문을 "요약으로 대신 답하기"로 바꾸는 부작용이 생길 수 있어요. 질문셋에 복사 요청 문항이 하나뿐이라 그 부작용을 확인하기도 어려워요. 또 지어낸 내용 없이 **안전한 쪽으로 실패**하는 경우라서 알려진 한계로 기록해요. 질문셋의 기대값은 바꾸지 않았어요.

3차 — 하이브리드 검색

항목	값
실행 일시	2026-11-04 13:04 KST (평가 완료 시각)
코드	`e64d09d` + 2차 보정 + 하이브리드 검색 + 보정 표현 2개 추가 (커밋 전)

문제

3차 3회차부터 청크 Recall@5 0.787, MRR 0.778, nDCG@5 0.751로 목표에 못 미쳤어요. 벡터 검색만 써서 작품명·기법명·연도처럼 단어가 정확히 맞아야 하는 질문에서 생애·연표 같은 긴 문서가 위로 올라왔어요. 게다가 이 점수는 평가 스크립트가 벡터 거리로 **따로** 계산하고 있어서, 검색기를 바꿔도 점수가 움직이지 않는 구조였어요.

바꾼 것

파일	내용
`llm/rag/hybrid.py` (새 파일)	순위 함수. 한국어 BM25(kiwipiepy로 명사·고유명사·숫자만 색인, 작가 별칭을 사용자 사전에 등록)와 벡터 순위를 RRF로 합침. `점수 = 1/(60+벡터 순위) + 2/(60+BM25 순위)`
`llm/rag/retriever.py`	범위 청크를 `get()`으로 모두 받아 하이브리드 순위를 매김. 작품 해설 자리(3), 비교 문서 자리(2), 문서별 상한(2), 항상 넣는 청크 규칙은 그 순위 위에서 그대로 적용. Chroma 근사 검색(`query`)은 쓰지 않음
`scripts/eval_round3.py`	청크 점수를 검색기와 같은 순위 함수로 계산. 3차 비교용 벡터 순위 점수도 같이 기록
`llm/docent/grounding.py`	2차 보정 규칙에 표현 2개 추가 (아래「보정 규칙 보완」)

DB와 Chroma에는 아무것도 쓰지 않아요. 테이블·인덱스·임베딩도 바뀌지 않아요. 의존성 `kiwipiepy`, `rank-bm25`가 추가됐어요.

방식 고르기: 18문항 메모리 실험

코드를 바꾸기 전에, 평가와 같은 청크·질문으로 순위 방식만 바꿔 비교했어요.

방식	Recall@5 (0.85)	MRR (0.80)	nDCG@5 (0.80)
벡터만 (기존)	0.787 ❌	0.778 ❌	0.751 ❌
BM25만	0.898	0.917	0.877
RRF 1:1	0.843 ❌	0.806	0.789 ❌
RRF, BM25 비중 2배 (채택)	**0.870**	**0.852**	**0.828**

- RRF의 k(10·30·60)와 BM25 비중(1.5·2·3)을 바꿔도, 비중이 1.5배 이상이면 모두 목표를 넘었어요. 특정 값 하나에 맞춘 결과가 아니에요.
- BM25만 쓰지 않은 이유: 정답표는 질문과 정답 청크가 같은 단어를 공유하는 경우가 많아 BM25에 유리해요. 바꿔 말한 질문은 벡터가 잘 찾으므로 둘을 합쳤어요.

3차 결과

테스트	결과
백엔드 테스트	**169/169 (하이브리드 순위·검색기 4개, 보정 표현 2개 추가)**
청크 검색 18문항 (하이브리드)	**Recall@5 0.8704 · MRR 0.8518 · nDCG@5 0.8281 · Hit@5 94.4%**
문서 검색 23문항	**23/23 (100%) 유지**
종합 평가 45문항	**44/45 (97.8%)**
검색 시간 (작품 5개 × 질문 2개)	하이브리드 약 1.5~2.0초, 3차 검색기 약 1.3~2.3초로 같은 수준이에요. 대부분 질문 임베딩과 Chroma 네트워크 시간이에요.

청크 문항	벡터 순위	하이브리드	정답 청크
`boundary-001`	1/2	**2/2**	《인상, 해돋이》 4·5번
`boundary-002`	0/2	**1/2**	《야경》 영문 해설 0·1번 (영문이라 한국어 키워드로는 한계)
`boundary-003`	0/2	**1/2**	명암법 비교 문서 12·13번
`prompt-002`	1/1 (2위)	**1/1 (1위)**	《별이 빛나는 밤》 해설 0번
`prompt-008`	2/3	2/3	추성부도 묵서 1·2·3번
`detail-007`	0/1	0/1	세잔 《사과와 오렌지》 해설 0번 (질문 단어가 정답 청크와 잘 겹치지 않음)

검색이 좋아지면서 답변도 달라졌어요. `prompt-008`은 묵서 청크를 더 잘 받아서, 이번에는 요약을 쓰고 `refused=false`로 답해 통과했어요. 그래서 오거절·출처 지표가 37/37이 됐어요. `detail-007`은 이 지표에서는 놓치지만, 실제 답변에서는 작품 해설 자리 보장으로 해설이 출처로 들어가요.

보정 규칙 보완

하이브리드만 적용해서 처음 돌렸을 때는 종합 43/45, `refused` 6/8이었어요. 근거가 바뀌면서 모델의 말투도 바뀌어, 2차 규칙의 표현 목록에 없는 문장이 나왔어요.

문항	첫 문장	추가한 표현
`evidence-002`	…정확히 단정하는 것은 제공된 자료만으로는 어렵습니다.	`자료만으로는 … 어렵`
`prompt-001`	…이어지는 부분이 누락되어 있습니다.	`누락되어 있`

추가한 규칙을 먼저 지난 모든 실행의 `refused=false` 답변 331건에 적용했어요. 바로잡은 답은 10건에서 12건으로 늘었고, 정상 답변을 잘못 거절한 경우는 0건이었어요. 그다음 45문항을 다시 돌린 결과가 위의 「3차 결과」예요.

남은 실패: `evidence-002`

- 질문: 고흐는 이 침실을 그리던 순간 행복했어, 우울했어? 둘 중 하나로 정확히 단정해줘.
- 답변: 첫 문장에서 작품 의도("색으로 휴식과 잠의 느낌을 주고자 한 작품")를 설명하고, **마지막 문장**에서 "둘 중 하나로 정확히 단정하기는 어렵습니다"라고 결론을 내려요. `refused=false`예요.
- 판정: 행복이나 우울 중 하나를 고르지 않았으니 지어낸 답은 아니에요. 보정 규칙은 일부만 답하는 정상 답변을 보호하려고 첫 문장만 보는데, 결론이 마지막에 있어서 걸리지 않았어요. 3차 3회차·6회차에도 나온 유형이에요.

청크 단위 검색 — 1·2차 (벡터 순위)

1·2차는 검색을 바꾸지 않아서 3차 6회차와 소수점까지 같았어요. 4차 3차의 하이브리드 결과는 위「3차 결과」에 있어요. 이 지표는 서버 답변을 거치지 않고 질문 임베딩과 청크 임베딩의 거리만으로 상위 5개를 뽑아 재요. 그래서 그래프나 검증 규칙을 바꿔도 움직이지 않고, LLM 무작위성도 없어요.

overlap	Hit@5	Recall@5	MRR	nDCG@5
0자 (현재)	83.3%	0.7870	0.7778	0.7514
50자	83.3%	0.7685	0.7778	0.7413
100자	77.8%	0.7500	0.7778	0.7563

정답을 놓친 문항	놓친 정도	정답 청크
`detail-007`	완전히 놓침	세잔《사과와 오렌지》해설 0번
`boundary-002`	완전히 놓침	《야경》영문 해설 0·1번
`boundary-003`	완전히 놓침	명암법 비교 문서 12·13번
`boundary-001`	2개 중 1개	《인상, 해돋이》4·5번
`prompt-008`	3개 중 2개	추성부도 묵서 1·2·3번

작품명, 기법명, 특정 단어가 중요한 질문에서 생애·연표처럼 긴 문서가 의미상 비슷하다고 위로 올라왔어요. 벡터 검색만 쓰는 한계였고, 4차 3차에서 하이브리드 검색으로 해결했어요.

다음 조치

순서	대상	조치	기대 효과
1	경계 문항의 흔들림 (`evidence-002`, `prompt-008` 등)	관련도 기준선, "근거 부족하면 다시 찾기" 루프. 경계 문항은 여러 번 돌려 통과율로 비교	실행마다 달라지는 결과 감소
2	보정 규칙의 표현 목록 한계	새 표현이 계속 나오면 LLM 판정(핵심 요청을 수행했는지)으로 바꾸기	`refused` 정합성 8/8 안정화
3	청크 검색 추가 개선 (선택)	영문 청크(`boundary-002`)와 바꿔 말한 질문(`detail-007`)은 Rerank 검토. 정답표 문항 늘리기	BM25에 유리한 정답표의 치우침 확인

산출물

- `docs/eval/rag-langgraph-local-2026-11-04.json`: 1차 45문항 결과
- `docs/eval/rag-refused-fix-local-2026-11-04.json`: 2차 45문항 결과
- `docs/eval/rag-3rd-sameday-local-2026-11-04.json`: 같은 날 3차 원래 코드 45문항 결과
- `docs/eval/rag-hybrid-local-2026-11-04.json`: 3차 하이브리드만 적용한 첫 실행 (보정 표현 추가 전)
- `docs/eval/rag-hybrid-rule-local-2026-11-04.json`: 3차 최종 45문항 결과 (청크 벡터·하이브리드 점수 포함)
- `docs/eval/retrieval-langgraph-local-2026-11-04.json`, `retrieval-hybrid-local-2026-11-04.json`: 문서 검색 23문항 결과 (1차, 3차)
- `docs/eval/docent-graph-equivalence/{3rd,4th}/`: 1차 동일성 비교 원시 기록

- `docs/docent_graph.mmd`: 그래프 구조도 (mermaid)
- 재현: `backend/` 에서 로컬 서버를 띄운 뒤 `uv run --group legacy python -m scripts.eval_round3 --base-url http://127.0.0.1:8010 --out ../docs/eval/<파일>.json`