# 4차 테스트 결과서

SKN35 4차 1팀 · 1차 LangGraph 적용 · 2차 `refused` 정합성 보정 · 3차 하이브리드 검색 · 4차 Django 이식 · 배포 통합 테스트 · 2026-11-04~05

**결론**

- **1차 (LangGraph 적용)**: 답변 흐름을 그래프 하나로 바꿨어요. 같은 날 3차 원래 코드와 비교하면 **41/45 → 42/45**로 같은 수준이고, 검색 청크와 자동 검사는 39/39 모두 같아요. 구조만 바뀌고 동작은 그대로라는 게 확인됐어요.
- **2차 (`refused` 보정)**: 검증 단계에 서버 규칙을 추가했어요. **`refused` 정합성 6/8 → 8/8**, 종합 **44/45 (97.8%)**예요. 3차부터 이어진 개선 과제를 해결했어요.
- **3차 (하이브리드 검색)**: 벡터 검색에 한국어 BM25를 RRF로 합쳤어요. **청크 Recall@5 0.787 → 0.870, MRR 0.778 → 0.852, nDCG@5 0.751 → 0.828**로, 3차부터 미달이던 세 지표가 모두 목표를 넘었어요. 근거가 좋아지면서 오거절·출처 지표도 **37/37(100%)**이 됐고, 종합은 **44/45 (97.8%)**예요.
- **4차 (Django 이식, 최종)**: 백엔드를 FastAPI에서 Django + Ninja로 옮기고 DB 접근을 Django ORM으로 바꿨어요. API 54개와 조회 응답 393건이 이식 전과 같아요. 보정 규칙이 결론 문장도 보게 해서 **`refused` 정합성 8/8**, 종합 **44/45 (97.8%)**예요.
- **기준 변경**: 오거절·출처 지표의 목표를 3차의 100%에서 **95% 이상**으로 바꿨어요(아래「기준 변경」). 4차 4차 결과는 바꾼 기준으로 통과하고, 3차 기준(100%)으로는 36/37로 미달이에요.
- **배포 환경 통합 테스트 (EC2)**: 배포 주소로 화면·API·인증·채팅·보안 31개 항목을 확인했고 **29/31 통과**예요. 같은 45문항 평가는 **44/45 (97.8%)**, `refused` 8/8이고, 로컬에서 0.06초 넘었던 **P95는 배포 환경에서 6.68초**로 목표를 통과했어요.
- **남은 것**: (1) HTTPS가 아직 없어요(80번만 열림). (2) 서버가 쉬다가 받은 첫 요청이 느려요(첫 API 23.0초, 첫 채팅 12.3초). (3) `X-Content-Type-Options` 응답 헤더가 빠졌어요. (4) `prompt-008`은 2차부터 기록한 알려진 경계 문항이에요.

## 한눈에 보기

45문항 종합 평가(`eval_round3`) 기준이에요. 판정은 4차 4차(최종)와 배포 환경 결과 기준이고, 응답 시간은 배포 환경으로 판정해요.

| 지표 | 목표 | 3차 최종 6회차 (10-15) | 3차 같은 날 (11-04) | 4차 1차 LangGraph | 4차 2차 + refused 보정 | 4차 3차 + 하이브리드 | 4차 4차 Django 이식 | 배포 EC2 (11-05) | 판정 |
|---|---|---|---|---|---|---|---|---|---|
| HTTP 성공률 | 99% 이상 | 45/45 | 45/45 | 45/45 | 45/45 | 45/45 | 45/45 | 45/45 | 통과 |
| 종합 통과율 | 90% 이상 | 43/45 (95.6%) | 41/45 (91.1%) | 42/45 (93.3%) | 44/45 (97.8%) | **44/45 (97.8%)** | 44/45 (97.8%) | 44/45 (97.8%) | 통과 |
| `refused` 정합성 | 별도 기록 | 6/8 | 6/8 | 6/8 | **8/8** | 7/8 | **8/8** | 8/8 | 해결 |
| 정상 질문 오거절 없음 | 95% 이상 (3차 100%) | 37/37 | 35/37 (94.6%) | 36/37 (97.3%) | 36/37 (97.3%) | **37/37 (100%)** | 36/37 (97.3%) | 36/37 (97.3%) | 통과 |

| | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| 출처 포함 · 정합 · URL/라이선스 | 95% 이상 (3차 100%) | 37/37 | 35/37 (94.6%) | 36/37 (97.3%) | 36/37 (97.3%) | **37/37 (100%)** | 36/37 (97.3%) | 36/37 (97.3%) | **통과** |
| Faithfulness | 0.90 이상 | 0.9865 | 0.9432 | 0.9757 | 0.9797 | 0.9878 | 0.9716 | 0.9878 | **통과** |
| Answer Relevancy | 0.85 이상 | 1.0000 | 0.9730 | 1.0000 | 1.0000 | 0.9973 | 1.0000 | 0.9932 | **통과** |
| Answer Correctness | 0.85 이상 | 1.0000 | 0.9703 | 0.9986 | 1.0000 | 0.9946 | 0.9811 | 0.9946 | **통과** |
| 금지 주장 (자동 키워드 검사) | 0건 | 0 | 0 | 0 | 0 | 1 → 확인 후 0 | 0 | 0 | **통과** |
| P50 / P95 | P95 10초 이하 | 4.40 / 5.86초 | 4.55 / 8.06초 | 4.66 / 7.98초 | 5.17 / 8.81초 | 4.82 / 7.51초 | **5.56 / 10.06초** | **5.15 / 6.68초** | **통과 (배포)** |
| 말투 easy / standard / deep | 구분 가능 | 0.90/0.90/0.95 | 0.90/0.90/0.95 | 0.90/0.90/0.95 | 0.90/0.85/0.95 | 0.80/0.90/0.95 | 0.90/0.85/0.95 | 0.90/0.85/0.95 | **통과** |
| 문서 Hit@5 | 90% 이상 | 23/23 | — | 23/23 | — | 23/23 | 23/23 | — | **통과** |
| 청크 Recall@5 | 0.85 이상 | 0.7870 | 0.7870 | 0.7870 | 0.7870 | **0.8704** | 0.8704 | 0.8704 | **통과** |
| 청크 MRR | 0.80 이상 | 0.7778 | 0.7778 | 0.7778 | 0.7778 | **0.8518** | 0.8518 | 0.8518 | **통과** |
| 청크 nDCG@5 | 0.80 이상 | 0.7514 | 0.7514 | 0.7514 | 0.7514 | **0.8281** | 0.8281 | 0.8281 | **통과** |
| 백엔드 테스트 | 전체 통과 | 158 | 158 | 158 | 163 | **169** | **171** | — | **통과** |

- 3차 6회차는 Railway 배포 결과이고, 나머지는 로컬 결과예요. 응답 시간은 환경 차이가 섞여 있어요.
- 오거절·출처 지표는 4차부터 바꾼 기준(95% 이상)으로 판정했어요. 3차 기준(100%)을 그대로 쓰면 4차 1차·2차 모두 미달이에요.
- "3차 같은 날"은 오늘 3차 원래 코드를 그대로 다시 돌린 결과예요. 같은 날·같은 데이터로 비교하려고 넣었어요.
- "—"는 그 실행에서 돌리지 않은 항목이에요. 2차는 검색 코드가 바뀌지 않아 1차 문서 검색 결과가 그대로 유효해요.
- 청크 점수는 1·2차까지 벡터 순위, 4차 3차부터는 운영 검색기와 같은 하이브리드 순위예요. 같은 18문항의 벡터 순위 점수(0.787)도 비교용으로 계속 기록해요.
- 4차 3차까지는 로컬 FastAPI, 4차 4차는 로컬 Django 결과예요. 4차 4차의 P95는 단독 실행으로 쟀고, 답변 모델 응답 시간이 포함돼요.
- "배포 EC2"는 같은 45문항을 배포 주소(`http://13.125.176.74`)로 보낸 결과예요. 청크 점수는 서버 응답이 아니라 같은 데이터로 계산하는 지표라 4차 4차와 같아요. 문서 검색과 백엔드 테스트는 로컬에서만 돌려서 "—"로 뒀어요.
- 4차 3차의 금지 주장 자동 검사 1건(`detail-004`)은 "후대에 만들어진 '마지막 작품' 신화와 구분해야 한다"처럼 그 주장을 부정하는 문맥이에요. 글자만 보는 자동 검사의 오탐이라, 직접 확인한 뒤 0건으로 판정했어요.

## 기준 변경

| 지표 | 3차 목표 | 4차 목표 |
|---|---|---|
| 정상 질문 오거절 없음 | 100% | **95% 이상** |
| 출처 포함률 · 기대 문서 정합률 · URL·라이선스 필드 완전성 | 100% | **95% 이상** |

**바꾼 이유**

- **정상 질문 37개 중 1개만 틀려도 미달이에요.** 100%는 경계 문항 하나의 무작위 결과에 판정이 좌우돼요. 실제로 3차 코드에서도 같은 문항(`prompt-008`)이 회차마다 통과·실패가 갈려서, 3차 6회차는 100%, 같은 코드로 오늘 다시 돌리면 94.6%가 나왔어요.
- **이 지표들의 실패는 안전한 쪽 실패예요.** 답을 아끼거나 출처를 붙이지 않은 경우이고, 없는 내용을 지어낸 건 아니에요. 지어낸 내용과 직접 관련된 지표(금지 주장 0건, 거절 필요 질문의 `refused` 정합성, Faithfulness)는 바꾸지 않았어요.
- **95%는 37문항 중 1문항까지 허용**하는 수준이에요. 2문항 이상 실패하면 미달이에요.

기준 변경과 상관없이 질문셋과 각 문항의 기대값은 3차와 같아요.

## 공통 실행 환경

| 항목 | 값 |
|---|---|
| 서버 | 1·2·3차: 로컬 FastAPI (4차 `127.0.0.1:8010`, 3차 비교군 `127.0.0.1:8011`). 4차: 로컬 Django (`uvicorn config.asgi:application`, `127.0.0.1:8000`). 배포: AWS EC2 `http://13.125.176.74` (Docker Compose, nginx → Django) |
| 데이터 | TiDB Cloud, Chroma Cloud. **읽기만 함**. 토큰 없는 익명 요청이라 대화 저장 없음. 4차는 3차 데이터를 복사한 `4th_project` DB를 씀 |
| 모델 | 답변·Judge `gpt-4.1-mini` (temperature 0.3), 임베딩 `text-embedding-3-small` |
| 프롬프트 | `docent-grounded-1.5.1` (1·2·3·4차 모두 변경 없음) |
| 질문셋 | 3차와 같음: 고정 회귀 30 + 프롬프트 정확도 9 + 말투 3 + 청크 경계 3 = 45문항, 청크 정답 18문항 |
| 종합 통과 규칙 | 3차 결과서와 같음: HTTP 성공, 기대 `refused` 일치, 출처가 필요한 정상 질문은 출처 포함·정합·메타데이터 완전. 이 규칙으로 3차 5회차를 다시 계산해도 결과서와 같은 43/45가 나옴 |

비밀값은 출력하거나 결과 파일에 저장하지 않았어요.

## 1차 — LangGraph 적용

| 항목 | 값 |
|---|---|
| 실행 일시 | 2026-11-04 09:29 KST (평가 완료 시각) |
| 코드 | 커밋 `e64d09d` (3차 기능 전체 이식, LangGraph 적용, TiDB 연결) |

### 바꾼 것

3차에서는 같은 답변 흐름이 두 곳에 따로 있었어요. 일반 답변(`service.answer`)과 스트리밍(`stream.answer_events`)이 각각 분류·범위 판정·검색·생성·검증을 했어요. 그래서 한쪽만 고치면 동작이 달라지고, 평가(일반 답변)와 실제 화면(스트리밍)이 서로 다른 코드를 거쳤어요. 1차에서는 이 흐름을 그래프 하나(`backend/llm/docent/graph.py`)로 합쳤어요.

```
classify —(거절 · 단답)→ 끝
   └→ scope —(범위 밖)→ 끝
        ├→ recommend → 끝
        └→ retrieve —(자료 없음)→ 끝
             └→ generate → validate → 끝
```

프롬프트, 검색기, 검증 규칙, 모델은 바꾸지 않았어요. 그래서 1차의 목적은 **"구조만 바뀌고 결과는 그대로인가"**를 확인하는 거예요.

### 테스트 구성과 결과

| 테스트 | 내용 | 결과 |
|---|---|---|
| 백엔드 테스트 | 3차 테스트 158개 (그래프를 거쳐 실행) | **158/158** |
| 로컬 HTTP 확인 | 그래프 갈래 5개를 실제 API로 호출 | **5/5** |
| 동일성 비교 | `eval_docent` 39문항을 3차·4차 코드로 각각 실행 | **39/39 동일** |
| 종합 평가 | `eval_round3` 45문항 | **42/45 (93.3%)** |
| 문서 검색 | `eval_retrieval` 23문항 | **23/23** |

### 로컬 HTTP 확인

| 갈래 | 질문 | 결과 |
|---|---|---|
| RAG (JSON) | 이 작품의 구도는 어떤 특징이 있어? | 근거 있는 답변, 출처 1개 |
| RAG (SSE) | 같은 질문, `/chat/stream` | 200, token 204개 → done, 출처 1개 |
| 범위 밖 | 오늘 저녁 뭐 먹을까? | 범위 안내 문구, `refused=true` |
| 추천 | 이 작품이랑 비슷한 작품 추천해줘 | 비슷한 작품 3점 |
| 단답 | 이 작가 이름이 뭐야? | "이 작품의 작가는 카라바조입니다." (검색·생성 없이 답함) |

### 동일성 비교 (39문항)

45문항 평가는 LLM 무작위성이 섞이므로, 그래프가 3차와 같은 단계를 거치는지는 따로 확인했어요. 검색 결과와 모델 입력·출력을 기록하는 `eval_docent`로 비교했어요.

| 자동 검사 | 3차 | 4차 1차 |
|---|---|---|
| 실행 오류 | 0 | 0 |
| `refused` 기대 일치 | 36/39 | 36/39 |
| 출처가 검색 결과 안에 있음 | 39/39 | 39/39 |
| 정답 근거 문서 검색 | 32/32 | 32/32 |
| 필수 문맥 전달 | 5/9 | 5/9 |
| **검색된 청크 목록이 같음** | | **39/39** |
| **거절 판단이 다른 문항** | | **0** |

### 1차 실패 문항

| ID | 3차 6회차 | 3차 같은 날 | 4차 1차 | 유형 |
|---|---|---|---|---|
| `evidence-001` | **통과** | **통과** | **실패** | 상태값 불일치 |
| `evidence-002` | **실패** | **실패** | **통과** | 상태값 불일치 |
| `prompt-001` | **실패** | **실패** | **실패** | 상태값 불일치 |
| `prompt-008` | **통과** | **실패** | **실패** | 과잉 거절 |
| `compare-003` | **통과** | **실패** | **통과** | 과잉 거절 |

같은 3차 코드에서도 날짜에 따라 실패 문항이 달라요. 답변 모델의 무작위성에 따라 결과가 흔들리는 **경계 문항**이에요. 4차 1차의 실패 3건도 모두 이 묶음 안에 있고, LangGraph 때문에 새로 생긴 실패 유형은 없어요.

## 2차 — `refused` 정합성 보정

| 항목 | 값 |
|---|---|
| 실행 일시 | 2026-11-04 11:01 KST (평가 완료 시각) |
| 코드 | `e64d09d` + 보정 변경 (`grounding.py`, `graph.py`, `test_docent_grounding.py`) |

### 문제

3차 4~6회차부터 남아 있던 문제예요. 답변 본문에는 "자료로 확인할 수 없다"고 써 놓고, 거절 여부 값은 `refused=false`로 보내는 경우가 있었어요. 내용이 틀린 게 아니라 **표시가 틀린 것**이에요. 모델이 `refused` 값을 직접 정하기 때문에 가끔 본문과 엇갈려요.

### 바꾼 것: 서버 검증 규칙 추가

프롬프트는 바꾸지 않았어요. 모델이 답을 만든 **다음**, 그래프의 `validate` 단계에서 서버가 한 번 더 검사해요. 아래 세 조건을 모두 만족하면 `refused=true`로 바로잡고, 이유를 밝힌 첫 문장만 남기고, 출처를 비워요.

| 조건 | 확인하는 것 | 예 |
|---|---|---|
| ① 질문 | "정확히"나 "단정"을 요구한다 | 사과가 **정확히** 몇 개인지 세어줘 |
| ② 답변 첫 문장 | 근거 부족 표현이 있다 (확인할 수 없 · 자료에 없 · 단정하기 어렵 · 언급되어 있지 않 등) | 개수가 **언급되어 있지 않습니다**. |
| ③ 답변 첫 문장 | "지만", "으나", "다만"이 없다 (있으면 일부는 답한 것으로 봄) | — |

| 질문 | 모델 답 첫 문장 | 결과 |
|---|---|---|
| 사과가 정확히 몇 개야? | 개수가 언급되어 있지 않습니다. | **거절로 바로잡음** |
| 별이 빛나는 밤은 언제 그렸고 별이 정확히 몇 개야? | 1889년 6월에 그린 작품입니다. | 그대로 (첫 문장에서 답함) |
| 빨래하는 여성들은 누구야? | 신원은 확인하기 어렵습니다. | 그대로 (정확한 답을 요구하지 않음) |
| 이 작품은 정확히 언제 그렸어? | 정확한 날짜는 알 수 없지만 1888년 가을입니다. | 그대로 ("지만" 있음) |

### 넣기 전 검증: 지난 답변 256건에 적용

규칙을 코드에 넣기 전에, 3차 3~6회차와 오늘 실행에서 나온 `refused=false` 답변 256건에 먼저 적용해 봤어요.

| 규칙 | 바로잡은 답 (기대 refused=true) | 잘못 거절한 정상 답 |
|---|---|---|
| 첫 문장 표현만 보는 규칙 (첫 시도) | 10 | 2 (`multiturn-002`, `prompt-004`) |
| **최종 규칙** (①+②+③) | **13** | **0** |

첫 시도에서 잘못 걸린 2건은 "모른다"는 말이 정답인 질문이었어요("확실히 말할 수 있어?", "여성들은 누구야?"). 그래서 질문 조건(①)과 단서 조건(③)을 더했어요. 위 사례들은 단위 테스트 5개로 고정했어요.

### 2차 결과

| 테스트 | 결과 |
|---|---|
| 백엔드 테스트 | **163/163 (보정 테스트 5개 추가)** |
| 종합 평가 45문항 | **44/45 (97.8%)** |
| `refused` 정합성 | **8/8** |

이번 실행에서 규칙이 실제로 바로잡은 답이에요. 둘 다 이유를 밝힌 첫 문장만 남았어요.

| ID | 최종 답변 |
|---|---|
| `evidence-002` | 빈센트 반 고흐가 《침실》을 그리던 순간을 행복하거나 우울하다고 단정하기는 어렵습니다. |
| `prompt-001` | 김홍도 필 추성부도의 묵서 번역은 '사람은 동물이'라는 구절에서 문장이 중간에 끊겨 이어지는 부분이 제공된 자료에 없습니다. |

일부만 답해야 하는 문항(`prompt-002`, `prompt-004`, `multiturn-002`)은 정상 답변으로 그대로 남았어요. `evidence-001`은 이번에는 모델이 스스로 거절했어요.

### 남은 실패: `prompt-008` 과잉 거절 (알려진 한계)

- 질문: 추성부도 해설의 묵서 번역을 처음부터 끝까지 그대로 복사해줘.
- 기대: 복사는 하지 않되 확인 가능한 내용을 요약하고, 번역이 중간에 끊긴다는 한계를 밝힌다 (`refused=false`).
- 실제: "현재 검수된 자료로는 정확한 확인이 어려워요." (`refused=true`, 출처 없음)

**원인**: 모델 출력 기록을 보면, 모델은 요약과 한계 설명을 제대로 썼어요. 그런데 표시값을 `refused=true`로 보내면서 근거 문서 ID도 함께 넣었어요. 서버의 안전 규칙은 "거절이면 근거 문서가 없어야 한다"라서 이 출력을 형식 오류로 보고 버려요. 2차 보정은 `refused=false → true` 방향만 바로잡으므로 이 문항과는 상관없어요.

| 실행 | 코드 | prompt-008 |
|---|---|---|
| 3차 3회차 · 4회차 (10-14) | 3차 | **실패 · 실패** |
| 3차 5회차 · 6회차 (10-15) | 3차 | **통과 · 통과** |
| 3차 같은 날 (11-04) | 3차 그대로 | **실패** |
| 4차 1차 · 2차 (11-04) | 4차 | **실패 · 실패** |

3차 최종(6회차)의 오거절·출처 100%는 이 경계 문항이 그 회차에 통과한 결과예요. 같은 날 3차 원래 코드로 다시 돌리면 같은 지표가 35/37이에요. 4차는 36/37(97.3%)로 같거나 조금 낮고, 4차 기준(95% 이상)으로 통과예요.

**고치지 않은 이유**: 해결하려면 모든 질문에 들어가는 프롬프트에 복사 요청 규칙을 추가해야 해요. 그러면 거절해야 할 질문을 "요약으로 대신 답하기"로 바꾸는 부작용이 생길 수 있어요. 질문셋에 복사 요청 문항이 하나뿐이라 그 부작용을 확인하기도 어려워요. 또 지어낸 내용 없이 **안전한 쪽으로 실패**하는 경우라서 알려진 한계로 기록해요. 질문셋의 기대값은 바꾸지 않았어요.

## 3차 — 하이브리드 검색

| 항목 | 값 |
|---|---|
| 실행 일시 | 2026-11-04 13:04 KST (평가 완료 시각) |
| 코드 | `e64d09d` + 2차 보정 + 하이브리드 검색 + 보정 표현 2개 추가 (커밋 전) |

### 문제

3차 3회차부터 청크 Recall@5 0.787, MRR 0.778, nDCG@5 0.751로 목표에 못 미쳤어요. 벡터 검색만 써서 작품명·기법명·연도처럼 단어가 정확히 맞아야 하는 질문에서 생애·연표 같은 긴 문서가 위로 올라왔어요. 게다가 이 점수는 평가 스크립트가 벡터 거리로 **따로** 계산하고 있어서, 검색기를 바꿔도 점수가 움직이지 않는 구조였어요.

### 바꾼 것

| 파일 | 내용 |
|---|---|
| `llm/rag/hybrid.py` (새 파일) | 순위 함수. 한국어 BM25(kiwipiepy로 명사·고유명사·숫자만 색인, 작가 별칭을 사용자 사전에 등록)와 벡터 순위를 RRF로 합침. `점수 = 1/(60+벡터 순위) + 2/(60+BM25 순위)` |
| `llm/rag/retriever.py` | 범위 청크를 `get()`으로 모두 받아 하이브리드 순위를 매김. 작품 해설 자리(3), 비교 문서 자리(2), 문서별 상한(2), 항상 넣는 청크 규칙은 그 순위 위에서 그대로 적용. Chroma 근사 검색(`query`)은 쓰지 않음 |
| `scripts/eval_round3.py` | 청크 점수를 검색기와 같은 순위 함수로 계산. 3차 비교용 벡터 순위 점수도 같이 기록 |
| `llm/docent/grounding.py` | 2차 보정 규칙에 표현 2개 추가 (아래「보정 규칙 보완」) |

DB와 Chroma에는 아무것도 쓰지 않아요. 테이블·인덱스·임베딩도 바뀌지 않아요. 의존성 `kiwipiepy`, `rank-bm25`가 추가됐어요.

### 방식 고르기: 18문항 메모리 실험

코드를 바꾸기 전에, 평가와 같은 청크·질문으로 순위 방식만 바꿔 비교했어요.

| 방식 | Recall@5 (0.85) | MRR (0.80) | nDCG@5 (0.80) |
|---|---|---|---|
| 벡터만 (기존) | 0.787 ❌ | 0.778 ❌ | 0.751 ❌ |
| BM25만 | 0.898 | 0.917 | 0.877 |
| RRF 1:1 | 0.843 ❌ | 0.806 | 0.789 ❌ |
| **RRF, BM25 비중 2배 (채택)** | **0.870** | **0.852** | **0.828** |

- RRF의 k(10·30·60)와 BM25 비중(1.5·2·3)을 바꿔도, 비중이 1.5배 이상이면 모두 목표를 넘었어요. 특정 값 하나에 맞춘 결과가 아니에요.
- BM25만 쓰지 않은 이유: 정답표는 질문과 정답 청크가 같은 단어를 공유하는 경우가 많아 BM25에 유리해요. 바꿔 말한 질문은 벡터가 잘 찾으므로 둘을 합쳤어요.

### 3차 결과

| 테스트 | 결과 |
|---|---|
| 백엔드 테스트 | **169/169 (하이브리드 순위·검색기 4개, 보정 표현 2개 추가)** |

| | |
|---|---|
| 청크 검색 18문항 (하이브리드) | **Recall@5 0.8704 · MRR 0.8518 · nDCG@5 0.8281 · Hit@5 94.4%** |
| 문서 검색 23문항 | **23/23 (100%) 유지** |
| 종합 평가 45문항 | **44/45 (97.8%)** |
| 검색 시간 (작품 5개 × 질문 2개) | 하이브리드 약 1.5~2.0초, 3차 검색기 약 1.3~2.3초로 같은 수준이에요. 대부분 질문 임베딩과 Chroma 네트워크 시간이에요. |

| 청크 문항 | 벡터 순위 | 하이브리드 | 정답 청크 |
|---|---|---|---|
| `boundary-001` | 1/2 | **2/2** | 《인상, 해돋이》 4·5번 |
| `boundary-002` | 0/2 | **1/2** | 《야경》 영문 해설 0·1번 (영문이라 한국어 키워드로는 한계) |
| `boundary-003` | 0/2 | **1/2** | 명암법 비교 문서 12·13번 |
| `prompt-002` | 1/1 (2위) | **1/1 (1위)** | 《별이 빛나는 밤》 해설 0번 |
| `prompt-008` | 2/3 | 2/3 | 추성부도 묵서 1·2·3번 |
| `detail-007` | 0/1 | 0/1 | 세잔 《사과와 오렌지》 해설 0번 (질문 단어가 정답 청크와 잘 겹치지 않음) |

검색이 좋아지면서 답변도 달라졌어요. `prompt-008`은 묵서 청크를 더 잘 받아서, 이번에는 요약을 쓰고 `refused=false`로 답해 통과했어요. 그래서 오거절·출처 지표가 37/37이 됐어요. `detail-007`은 이 지표에서는 놓치지만, 실제 답변에서는 작품 해설 자리 보장으로 해설이 출처로 들어가요.

### 보정 규칙 보완

하이브리드만 적용해서 처음 돌렸을 때는 종합 43/45, `refused` 6/8이었어요. 근거가 바뀌면서 모델의 말투도 바뀌어, 2차 규칙의 표현 목록에 없는 문장이 나왔어요.

| 문항 | 첫 문장 | 추가한 표현 |
|---|---|---|
| `evidence-002` | …정확히 단정하는 것은 제공된 자료만으로는 어렵습니다. | `자료만으로는 … 어렵` |
| `prompt-001` | …이어지는 부분이 누락되어 있습니다. | `누락되어 있` |

추가한 규칙을 먼저 지난 모든 실행의 `refused=false` 답변 331건에 적용했어요. 바로잡은 답은 10건에서 12건으로 늘었고, 정상 답변을 잘못 거절한 경우는 0건이었어요. 그다음 45문항을 다시 돌린 결과가 위의 「3차 결과」예요.

### 남은 실패: `evidence-002`

- 질문: 고흐는 이 침실을 그리던 순간 행복했어, 우울했어? 둘 중 하나로 정확히 단정해줘.
- 답변: 첫 문장에서 작품 의도("색으로 휴식과 잠의 느낌을 주고자 한 작품")를 설명하고, **마지막 문장**에서 "둘 중 하나로 정확히 단정하기는 어렵습니다"라고 결론을 내려요. `refused=false`예요.
- 판정: 행복이나 우울 중 하나를 고르지 않았으니 지어낸 답은 아니에요. 보정 규칙은 일부만 답하는 정상 답변을 보호하려고 첫 문장만 보는데, 결론이 마지막에 있어서 걸리지 않았어요. 3차 3회차·6회차에도 나온 유형이에요.

## 4차 — Django 이식 (최종)

| 항목 | 값 |
|---|---|
| 실행 일시 | 2026-11-04 14:12 KST (평가 완료 시각) |
| 코드 | 커밋 `6897074` (Django + 하이브리드 검색 + `refused` 보정 보완) |
| 실행 방식 | 로컬 Django 서버에 다른 작업 없이 단독 실행 |

### 바꾼 것

| 영역 | 3차 방식 | 4차 |
|---|---|---|
| API | FastAPI | Django + Django Ninja. 주소와 응답 형식 유지 |
| DB 접근 | SQLAlchemy, Alembic | Django ORM, 기존 테이블을 쓰는 `managed = False` 모델 22개 |
| DB | `3rd_project` | 복사한 `4th_project`. 전체 행 해시 일치 확인 후 전환 |
| 관리자 | 없음 | Django Admin (사조, 작가, 작품, 문서) |
| 코드 구조 | `backend/app` | `accounts`, `catalog`, `chat`, `library`, `documents` 앱 |

벡터 추천(`VEC_COSINE_DISTANCE`)과 열람 수 증가(`ON DUPLICATE KEY UPDATE`)는 ORM 표현이 없거나 원자성이 필요해서 SQL로 남겼어요.

### Django API 테스트

| 테스트 | 내용 | 결과 |
|---|---|---|
| 백엔드 테스트 | 기존 테스트와 보정 테스트 | 171/171 |
| 경로 비교 | 3차 API와 Django API의 경로와 메서드 | 54/54 일치 |
| 조회 응답 스냅샷 | 사용자 8명, 공개·로그인 API를 전환 전 응답과 비교 | 393/393 일치 |
| 함수 기준값 | 검색 범위, 출처, 추천 후보를 전환 전 결과와 비교 | 550/550 일치 |
| 쓰기 흐름 | 좋아요, 프로필, 컬렉션, 일기, 대화 저장, AI 기능. 저장 시각과 동시 요청 포함 | 44/44 |
| Firebase 로그인 | 실제 로그인 토큰으로 로그인 필요 API 5개 호출 (이식 후, 코드 이동 전) | 5/5 |
| 토큰 거절 | 토큰 없음, 잘못된 토큰, 위조 서명, 만료, 다른 프로젝트 | 모두 401 |
| 실제 서버 | `uvicorn`에서 조회, 일반 채팅, SSE, MCP 인증, CORS | **정상** |

쓰기 흐름은 임시 사용자로 돌린 뒤 지웠고, 테이블 건수가 시작 전과 같은지 확인했어요. 422와 405 오류의 세부 본문은 3차와 다르지만, 프론트는 이 내용을 쓰지 않아요.

### 보정 규칙 보완

3차 결과의 `evidence-002`처럼 작품을 먼저 설명하고 뒤 문장에서 결론을 내리는 답변이 첫 문장 규칙을 빠져나갔어요. Django + 하이브리드 코드의 첫 평가에서도 `refused`가 6/8이었어요. 두 가지를 고쳤어요.

| 변경 | 내용 |
|---|---|
| 표현 추가 | 근거 부족 표현에 "제공할 수 없" 추가 |
| 결론 문장 검사 | 뒤 문장은 "따라서", "그러나", "하지만", "그래서", "결론적으로"로 시작할 때만 검사 |

모든 문장을 보는 방식은 쓰지 않았어요. "1889년에 그렸습니다. 별 개수는 자료에 없습니다"처럼 핵심을 답하고 일부만 모르는 답변까지 거절하기 때문이에요. 넣기 전에 지난 답변 360건에 적용했고, 거절해야 할 답변 16건을 잡고 정상 답변을 잘못 거절한 경우는 0건이었어요.

### 남은 실패: `prompt-008`

2차와 같은 과잉 거절 문항이에요. 3차에서는 하이브리드 검색으로 통과했고, 이번 실행에서는 다시 실패했어요. 실행마다 통과·실패가 갈리는 경계 문항이고, 지어낸 내용 없이 안전한 쪽으로 실패한 경우예요.

### P95 10.06초

| 단독 측정 | P50 | P95 |
|---|---|---|
| Django, 하이브리드 적용 전 | 5.19초 | 8.87초 |
| Django + 하이브리드 | 5.61초 | 11.12초 |
| Django + 하이브리드 + 보정 보완 (최종) | 5.56초 | 10.06초 |

느린 문항이 실행마다 달라서 답변 모델의 응답 편차가 큰 것으로 보지만, 원인을 확정하지는 못했어요. Django는 요청마다 TiDB에 새로 연결해서 약 0.4초가 더 들어요. ASGI에서는 Django 문서가 영구 연결을 끄도록 안내해서 그대로 두었어요. 판정은 배포 환경 측정으로 해요.

## 배포 환경 통합 테스트 (EC2)

| 항목 | 값 |
|---|---|
| 실행 일시 | 2026-11-05 10:20~10:39 KST |
| 대상 | `http://13.125.176.74` (AWS EC2, Docker Compose: nginx → Django uvicorn) |
| 요청한 곳 | 개발 PC (한국) → EC2. 응답 시간에는 인터넷 왕복이 포함돼요 |
| 데이터 | 배포 서버가 쓰는 `4th_project` DB. **조회만 함**. 채팅은 로그인 없이 보내서 대화가 저장되지 않고, 로그인이 필요한 API는 토큰 없이 401이 나는지만 확인했어요 |

### 1. 배포 확인 31개 항목

| 영역 | 확인한 것 | 결과 |
|---|---|---|
| 화면·라우팅 (8) | `/` Flutter 화면, `flutter_bootstrap.js`, `main.dart.js` (gzip), Flutter 주소 새로고침 (`/artworks/1`), `/api/health`, `/api/docs`, `/admin/` → 로그인 이동(302), 관리자 CSS | **8/8** |
| 공개 API (8) | 사조 6개, 작가 10명, 작가 상세, 작품 277점, 작품 상세, 비슷한 작품, 공개 감상 피드, 없는 작품 404 | **8/8** |
| 인증 경계 (6) | 토큰 없이 프로필·컬렉션·좋아요·대화 기록 → 401, 잘못된 토큰 → 401, 토큰 없이 MCP → 401 (`WWW-Authenticate: Bearer`) | **6/6** |
| 채팅 (6) | JSON 답변 4갈래(RAG, 범위 밖 거절, 추천, 작가 단답), SSE 스트리밍(토큰 240개 → done, 출처 4개), nginx 버퍼링 없음(첫 토큰부터 마지막까지 1.64초에 걸쳐 나눠 도착) | **6/6** |
| 보안 (3) | 허용 안 된 Origin에 CORS 허용 안 함 | **통과** |
| | `X-Content-Type-Options: nosniff` 응답 헤더 | **없음** |
| | HTTPS(443) | **연결 안 됨** |
| **합계** | | **29/31** |

실패한 2건은 기능 문제가 아니라 배포 설정이 남은 항목이에요. HTTPS는 `infra/README.md`의 「남은 것」에 이미 적혀 있고, 도메인을 연결한 뒤 인증서를 붙일 예정이에요. 지금은 로그인 토큰이 암호화되지 않은 HTTP로 오가니까, 발표 전에 HTTPS를 붙이는 게 좋아요.

### 2. 첫 요청 지연 (콜드 스타트)

| 요청 | 서버가 쉬다가 받은 첫 요청 | 그 뒤 (3번 반복) |
|---|---|---|
| 사조 목록 `/api/movements` | **23.0초** | 0.44~0.49초 |
| RAG 질문 | **12.3초** | 6.1~6.5초 |

한 번 데워진 뒤에는 정상이에요. 첫 채팅이 느린 데는 형태소 분석기(Kiwi) 준비 약 1.4초와, 작가별 첫 청크 분석 약 0.5초가 포함돼요(로컬 측정). 첫 API의 23초는 서버 로그를 봐야 원인을 알 수 있어요. 아래 45문항 평가는 서버가 데워진 상태에서 시작했어요.

### 3. 45문항 종합 평가

| 지표 | 목표 | 로컬 Django (11-04) | 배포 EC2 (11-05) | 판정 |
|---|---|---|---|---|
| HTTP 성공률 | 99% 이상 | 45/45 | 45/45 | **통과** |
| 종합 통과율 | 90% 이상 | 44/45 | 44/45 (97.8%) | **통과** |
| `refused` 정합성 | 별도 기록 | 8/8 | 8/8 | **통과** |
| 정상 질문 오거절 없음 · 출처 | 95% 이상 | 36/37 | 36/37 (97.3%) | **통과** |
| Faithfulness / Relevancy / Correctness | 0.90 / 0.85 / 0.85 | 0.972 / 1.000 / 0.981 | 0.988 / 0.993 / 0.995 | **통과** |
| 금지 주장 (자동 키워드 검사) | 0건 | 0 | 0 | **통과** |
| **P50 / P95** | P95 10초 이하 | **5.56 / 10.06초** | **5.15 / 6.68초** | **통과** |
| 가장 느린 응답 | — | 14.23초 | 6.85초 | — |
| 말투 구분 | 구분 가능 | 0.90/0.85/0.95 | 0.90/0.85/0.95 | **통과** |

- **P95 판정**: 배포 환경에서 6.68초로 목표를 통과했어요. 로컬 Django 실행의 10.06초는 P95를 정한 느린 3문항이 모두 서버 첫 요청이나 작가별 첫 질문이었고, 배포 실행에서는 가장 느린 응답도 6.85초였어요. 다만 이 측정은 서버가 데워진 상태라서, 첫 요청 지연(2번)은 따로 남겨요.
- **남은 실패**: `prompt-008`(과잉 거절) 1건이에요. 로컬 Django 결과와 같은 문항이고, 2차부터 기록한 알려진 경계 문항이에요.

## 청크 단위 검색 — 1·2차 (벡터 순위)

1·2차는 검색을 바꾸지 않아서 3차 6회차와 소수점까지 같았어요. 4차 3차의 하이브리드 결과는 위「3차 결과」에 있어요. 이 지표는 서버 답변을 거치지 않고 질문 임베딩과 청크 임베딩의 거리만으로 상위 5개를 뽑아 재요. 그래서 그래프나 검증 규칙을 바꿔도 움직이지 않고, LLM 무작위성도 없어요.

| overlap | Hit@5 | Recall@5 | MRR | nDCG@5 |
|---|---|---|---|---|
| 0자 (현재) | 83.3% | 0.7870 | 0.7778 | 0.7514 |
| 50자 | 83.3% | 0.7685 | 0.7778 | 0.7413 |
| 100자 | 77.8% | 0.7500 | 0.7778 | 0.7563 |

| 정답을 놓친 문항 | 놓친 정도 | 정답 청크 |
|---|---|---|
| `detail-007` | 완전히 놓침 | 세잔《사과와 오렌지》해설 0번 |
| `boundary-002` | 완전히 놓침 | 《야경》영문 해설 0·1번 |
| `boundary-003` | 완전히 놓침 | 명암법 비교 문서 12·13번 |
| `boundary-001` | 2개 중 1개 | 《인상, 해돋이》4·5번 |
| `prompt-008` | 3개 중 2개 | 추성부도 묵서 1·2·3번 |

작품명, 기법명, 특정 단어가 중요한 질문에서 생애·연표처럼 긴 문서가 의미상 비슷하다고 위로 올라왔어요. 벡터 검색만 쓰는 한계였고, 4차 3차에서 하이브리드 검색으로 해결했어요.

## 다음 조치

| 순서 | 대상 | 조치 | 기대 효과 |
|---|---|---|---|
| 0 | HTTPS 없음 | 도메인 연결 후 인증서 발급, nginx 443 블록 추가, 80은 HTTPS로 이동 (`infra/README.md`) | 로그인 토큰이 암호화되어 전송 |
| 0 | 첫 요청이 느림 (23.0초 / 12.3초) | 배포 서버 로그로 원인 확인. 서버 시작 시 형태소 분석기와 청크 분석을 미리 준비(워밍업) | 첫 사용자의 대기 시간 감소 |
| 0 | `X-Content-Type-Options` 헤더 없음 | nginx에 `add_header X-Content-Type-Options nosniff always;` 추가 (3차 Vercel 설정에는 있었음) | 브라우저의 파일 형식 추측 차단 |
| 1 | 경계 문항의 흔들림 (`evidence-002`, `prompt-008` 등) | 관련도 기준선, "근거 부족하면 다시 찾기" 루프. 경계 문항은 여러 번 돌려 통과율로 비교 | 실행마다 달라지는 결과 감소 |
| 2 | 보정 규칙의 표현 목록 한계 | 새 표현이 계속 나오면 LLM 판정(핵심 요청을 수행했는지)으로 바꾸기 | `refused` 정합성 8/8 안정화 |
| 3 | 청크 검색 추가 개선 (선택) | 영문 청크(`boundary-002`)와 바꿔 말한 질문(`detail-007`)은 Rerank 검토. 정답표 문항 늘리기 | BM25에 유리한 정답표의 치우침 확인 |

## 산출물

- `docs/eval/rag-langgraph-local-2026-11-04.json`: 1차 45문항 결과
- `docs/eval/rag-refused-fix-local-2026-11-04.json`: 2차 45문항 결과
- `docs/eval/rag-3rd-sameday-local-2026-11-04.json`: 같은 날 3차 원래 코드 45문항 결과
- `docs/eval/rag-hybrid-local-2026-11-04.json`: 3차 하이브리드만 적용한 첫 실행 (보정 표현 추가 전)
- `docs/eval/rag-hybrid-rule-local-2026-11-04.json`: 3차 최종 45문항 결과 (청크 벡터·하이브리드 점수 포함)
- `docs/eval/rag-django-final-local-2026-11-04.json`: 4차 최종 45문항 결과 (Django)
- `docs/eval/rag-deploy-ec2-2026-11-05.json`: 배포 환경 45문항 결과
- `docs/eval/deploy-smoke-2026-11-05.json`: 배포 환경 확인 31개 항목 결과
- `docs/eval/retrieval-django-final-local-2026-11-04.json`: 4차 최종 문서 검색 23문항 결과
- `docs/eval/retrieval-langgraph-local-2026-11-04.json`, `retrieval-hybrid-local-2026-11-04.json`: 문서 검색 23문항 결과 (1차, 3차)
- `docs/eval/docent-graph-equivalence/{3rd,4th}/`: 1차 동일성 비교 원시 기록
- `docs/docent_graph.mmd`: 그래프 구조도 (mermaid)
- 재현: `backend/`에서 로컬 서버를 띄운 뒤 `uv run python -m scripts.eval_round3 --base-url http://127.0.0.1:8000 --out ../docs/eval/<파일>.json`