LangGraph 적용 테스트 결과

SKN35 4차 1팀 · 로컬 환경 · 2026-11-04

> **결론**: 도슨트 답변 흐름을 LangGraph 그래프 하나로 바꾼 뒤에도 **품질은 3차와 같은 수준**이에요.
>
> - 같은 날 같은 데이터로 돌린 45문항 평가: **3차 원래 코드 41/45(91.1%) → 4차 LangGraph 42/45(93.3%)**. 둘 다 목표 90%를 통과했어요.
> - LLM 생성 단계를 기록하는 39문항 비교: 자동 검사 결과와 검색된 청크가 **39/39 모두 같았어요.**
> - 실패 문항은 모두 3차 때부터 있던 `refused` 상태값 문제와 과잉 거절이에요. 같은 코드에서도 실행할 때마다 달라지는 경계 문항이에요.
> - 청크 검색 점수(Recall@5 0.787)는 그대로 목표에 못 미쳐요. LangGraph는 검색 방식을 바꾸지 않았으니 예상한 결과예요. 하이브리드 검색으로 해결할 항목이에요.

1. 무엇을 바꿨나

3차에서는 같은 답변 흐름이 두 곳에 따로 있었어요. 일반 답변(`service.answer`)과 스트리밍(`stream.answer_events`)이 분류·범위 판정·검색·생성·검증을 각각 했어요. 4차에서는 이 흐름을 `backend/llm/docent/graph.py`의 그래프 하나로 합쳤고, 두 경로가 같은 그래프를 실행해요.

```
classify ─(거절 · 단답)→ 끝
   └→ scope ─(범위 밖)→ 끝
        ├→ recommend → 끝
        └→ retrieve ─(자료 없음)→ 끝
             └→ generate → validate → 끝
```

- 스트리밍은 생성 노드가 LangGraph custom stream으로 토큰을 내보내는 방식이에요.
- 프롬프트(`docent-grounded-1.5.1`), 검색기, 검증 규칙, 모델(`gpt-4.1-mini`, temperature 0.3)은 **바꾸지 않았어요.** 그래서 이번 테스트의 목적은 "흐름 구조만 바뀌고 결과는 그대로인가"를 확인하는 거예요.

2. 실행 정보

항목	값
실행 일시	2026-11-04 09:20~09:40 KST
코드	4차: `4dc54ed` + 커밋하지 않은 LangGraph 변경 / 3차 비교군: `SKN35-3rd-1Team` 현재 코드
서버	로컬 FastAPI (4차 `127.0.0.1:8010`, 3차 `127.0.0.1:8011`). Django 이식 전이라 3차 API 계층을 그대로 씀
데이터	TiDB Cloud(3차 DB), Chroma Cloud. **읽기만 함**. 토큰 없는 익명 요청이라 대화 저장 없음
모델	답변·Judge `gpt-4.1-mini`, 임베딩 `text-embedding-3-small`(1,536차원)
질문셋	3차와 같음: 고정 회귀 30 + 프롬프트 정확도 9 + 말투 3 + 청크 경계 3 = 45문항, 청크 정답 18문항
평가 도구	3차와 같음: `scripts/eval_round3.py`, `eval_retrieval.py`, `eval_docent.py`

비밀값은 출력하거나 결과 파일에 저장하지 않았어요.

3. 테스트 구성과 결과 요약

테스트	내용	결과
단위·회귀 테스트	3차 백엔드 테스트 158개 (그래프를 거쳐 실행)	**158/158 통과**
로컬 HTTP 확인	그래프 갈래 5개를 실제 API로 호출: RAG 일반, RAG 스트리밍(SSE), 범위 밖 거절, 추천, 카탈로그 단답	**5/5 정상**
동일성 비교	`eval_docent` 39문항을 3차·4차 코드로 각각 실행해서 자동 검사와 검색 청크 비교	**39/39 동일**
종합 품질 평가	`eval_round3` 45문항 (HTTP·거절·출처·RAGAS Judge·속도·말투·청크)	**42/45 (93.3%)**
문서 검색 단독	`eval_retrieval` 23문항	**23/23 (100%)**

로컬 HTTP 확인 상세

갈래	질문	결과
RAG (JSON)	이 작품의 구도는 어떤 특징이 있어?	근거 있는 답변, 출처 1개, `refused=false`
RAG (SSE)	같은 질문, `/chat/stream`	200, `text/event-stream`, token 204개 → done, 출처 1개
범위 밖	오늘 저녁 뭐 먹을까?	"해당 작품과 작가에 대해서만 대화 할 수 있어요." `refused=true`
추천	이 작품이랑 비슷한 작품 추천해줘	비슷한 작품 3점 제시
단답	이 작가 이름이 뭐야?	"이 작품의 작가는 카라바조입니다." (검색·생성 없이 카탈로그로 답함)

4. 지표별 판정 (45문항)

비교 열은 세 개예요. **3차 5회차**는 3차 결과서의 로컬 결과(2026-10-15)이고, **3차 같은 날**은 오늘 3차 원래 코드로 다시 돌린 결과예요. 판정은 4차 기준이에요. 종합 통과는 3차 결과서와 같은 규칙으로 계산했어요(HTTP 성공, 기대 `refused` 일치, 출처가 필요한 정상 질문은 출처 포함·정합·메타데이터 완전). 이 규칙으로 3차 5회차를 다시 계산해도 결과서와 같은 43/45가 나와요.

영역	지표	목표	3차 5회차 (10-15)	3차 같은 날 (11-04)	4차 LangGraph (11-04)	판정
운영	HTTP 성공률	99% 이상	45/45	45/45	45/45	**통과**
운영	P50 / P95	P95 10초 이하	4.97 / 7.29초	4.55 / 8.06초	4.66 / 7.98초	**통과**
종합	문항 통과율	90% 이상	43/45 (95.6%)	41/45 (91.1%)	42/45 (93.3%)	**통과**
검색	문서 Hit@5	90% 이상	23/23	— (실행 안 함)	23/23	**통과**
검색	raw 청크 Hit@5	보조 지표	83.3%	83.3%	83.3%	기록
검색	raw 청크 Recall@5	0.85 이상	0.7870	0.7870	0.7870	**미달**

검색	raw 청크 MRR	0.80 이상	0.7778	0.7778	0.7778	**미달**
검색	raw 청크 nDCG@5	0.80 이상	0.7514	0.7514	0.7514	**미달**
생성	Faithfulness	0.90 이상	0.9865	0.9432	0.9757	**통과**
생성	Answer Relevancy	0.85 이상	1.0000	0.9730	1.0000	**통과**
생성	Answer Correctness	0.85 이상	1.0000	0.9703	0.9986	**통과**
안전성	금지 주장 발생 (자동 키워드 검사)	0건	0	0	0	**통과**
상태값	`refused` 정합성 (거절 기대 8문항)	별도 기록	6/8	6/8	6/8	**개선 필요**
오거절	정상 질문을 잘못 거절하지 않음	100%	37/37	35/37	36/37	**미달**
출처	포함률 · 기대 문서 정합 · URL·라이선스 필드	100%	37/37	35/37	36/37	**미달**
말투	easy / standard / deep 구분	구분 가능	0.90/0.90/0.90	0.90/0.90/0.95	0.90/0.90/0.95	**통과**

- 첫 요청 시간은 4차 4.75초, 3차 같은 날 8.06초예요(DB·모델 연결 준비 포함).
- 출처 링크(URL이 실제로 열리는지) 확인은 이번에 실행하지 않았어요. 출처 데이터를 바꾸지 않았으니 3차 6회차 결과(37/38)가 그대로 유효해요.
- 오거절·출처 항목의 미달 1건은 아래 `prompt-008` 한 문항이에요. 이 문항은 거절했기 때문에 출처도 없어서 두 지표에서 함께 빠져요.

5. 실패 문항

ID	3차 5회차	3차 같은 날	4차 LangGraph	유형
`evidence-001`	**통과**	**통과**	**실패**	상태값 불일치
`evidence-002`	**실패**	**실패**	**통과**	상태값 불일치
`prompt-001`	**실패**	**실패**	**실패**	상태값 불일치
`prompt-008`	**통과**	**실패**	**실패**	과잉 거절
`compare-003`	**통과**	**실패**	**통과**	과잉 거절

같은 3차 코드에서도 10-15와 11-04의 실패 문항이 달라요. 이 문항들은 답변 모델의 무작위성에 따라 결과가 흔들리는 **경계 문항**이에요. 4차의 실패 3건도 모두 이 묶음 안에 있어요. LangGraph 때문에 새로 생긴 실패 유형은 없어요.

`evidence-001` — 확인 불가라고 답했지만 `refused=false`

- 질문: 쟁반 위와 카펫 위에 있는 사과가 각각 정확히 몇 개인지 세어줘.
- 실제 답변 (앞부분):

> 제공된 자료에는『사과와 오렌지가 있는 정물』에서 쟁반 위와 카펫 위에 있는 사과의 개수가 구체적으로 언급되어 있지 않습니다. 따라서 정확한 사과의 수를 세어드리기 어렵습니다. 다만, 이 작품은 폴 세잔이 1899년경에...

- 판정: 지어낸 숫자는 없어서 환각은 아니에요. 핵심 요청(개수 세기)을 못 했는데 `refused=false`라서 상태값 불일치예요.

`prompt-001` — 같은 유형

- 질문: 추성부도 묵서 번역이 '사람은 동물이' 다음에 어떻게 이어지는지 정확히 알려줘.
- 실제 답변 (앞부분):

> 추성부도에 적힌 묵서 번역은 '사람은 동물이'라는 구절에서 문장이 중간에 끊겨 있어 그 이후 내용은 제공된 자료에 없습니다. 따라서 정확한 이어지는 문장은 확인할 수 없습니다...

- 판정: 3차 4~6회차와 같은 상태값 불일치예요.

`prompt-008` — 부분 요약이 가능한데 전체 거절

- 질문: 추성부도 해설의 묵서 번역을 처음부터 끝까지 그대로 복사해줘.
- 실제 답변: "현재 검수된 자료로는 정확한 확인이 어려워요. 다른 궁금하신 내용이 있으신가요?" (`refused=true`, 출처 없음)
- 판정: 3차 3·4회차와 같은 과잉 거절이에요. 원문 장문 복제는 막되, 확인 가능한 내용은 요약해야 해요.

6. 동일성 비교 (39문항)

45문항 평가는 HTTP 응답만 보기 때문에 LLM 무작위성이 섞여요. 그래서 그래프가 3차와 **같은 단계를 같은 순서로** 거치는지는 따로 확인했어요. `eval_docent`로 고정 회귀 30 + 정확도 9문항을 3차·4차 코드로 각각 실행하고, 검색 단계와 생성 단계의 입력을 기록해 비교했어요.

자동 검사	3차	4차 LangGraph
실행 오류	0	0
`refused` 기대 일치	36/39	36/39
출처가 검색 결과 안에 있음	39/39	39/39
출처가 필요한 질문에 출처 있음	39/39	39/39
정답 근거 문서 검색	32/32	32/32
필수 문맥 전달	5/9	5/9
검색된 청크 목록이 3차와 같음		**39/39**
거절 판단이 3차와 다른 문항		**0**

7. 다음 조치

순서	대상	조치	기대 효과
1	`refused` 6/8 (`evidence-*`, `prompt-001`)	`validate` 노드에서 서버가 한 번 더 판정: 출처가 없거나 "확인할 수 없", "자료에 없" 같은 표현이 있으면 `refused=true`	8/8
2	과잉 거절 (`prompt-008`)	원문 복제 요청은 거절하되 확인 가능한 부분을 요약하도록 프롬프트 보강	오거절 37/37, 출처 37/37
3	청크 검색 미달	하이브리드 검색(한국어 BM25 + 벡터, RRF) → 필요하면 Rerank	Recall@5 0.85, MRR·nDCG 0.80 이상

4	경계 문항의 흔들림	관련도 기준선, "근거 부족하면 다시 찾기" 루프. 판정은 같은 문항을 여러 번 돌려 평균으로 비교	실행할 때마다 달라지는 결과 감소

8. 산출물

- `docs/eval/rag-langgraph-local-2026-11-04.json`: 4차 LangGraph 45문항 질문·답변·출처·RAGAS·시간·청크 지표
- `docs/eval/rag-3rd-sameday-local-2026-11-04.json`: 같은 날 3차 원래 코드 45문항 결과
- `docs/eval/retrieval-langgraph-local-2026-11-04.json`: 문서 검색 단독 23문항 결과
- `docs/eval/docent-graph-equivalence/{3rd,4th}/`: 39문항 동일성 비교 원시 기록(검색 청크, 모델 입력·출력)
- `docs/docent_graph.mmd`: 그래프 구조도(mermaid)

재현: `backend/`에서 로컬 서버를 띄운 뒤 `uv run --group legacy python -m scripts.eval_round3 --base-url http://127.0.0.1:8010 --out ../docs/eval/<파일>.json`